



Análisis Exploratorio e Inferencial de Exportaciones Colombianas

(Junio 2026)

Angie Montero
Michael Baquero

Analítica Descriptiva II
Unicafam
Octubre 2026

1. Introducción

El comercio exterior es uno de los pilares de la actividad económica colombiana, y su seguimiento estadístico permite comprender el comportamiento de los sectores productivos que participan en él [1]. La Dirección de Impuestos y Aduanas Nacionales (DIAN), en conjunto con el Departamento Administrativo Nacional de Estadística (DANE), produce y certifica mensualmente las estadísticas oficiales de exportaciones del país, las cuales constituyen una de las fuentes más completas y confiables para el análisis cuantitativo de esta actividad [2]. Dentro de estas estadísticas, variables como el valor FOB, el peso de la mercancía y los costos de flete permiten caracterizar no solo cuánto exporta el país, sino también bajo qué condiciones logísticas y económicas se realizan dichas operaciones.

A pesar de la disponibilidad de esta información, no es evidente a simple vista cómo se relacionan el peso de las mercancías exportadas con su valor comercial y con los costos asociados al transporte internacional. Comprender esta relación es relevante tanto para empresas exportadoras, que buscan optimizar sus costos logísticos, como para quienes diseñan política de comercio exterior, interesados en identificar patrones de eficiencia según el tipo de mercancía o el modo de transporte utilizado. De este panorama surge la pregunta de investigación que orienta el presente proyecto: **¿cómo se relaciona el peso de las mercancías con el valor FOB y los costos de flete en las exportaciones colombianas de junio de 2026?**

Para responder a esta pregunta, se plantean los siguientes objetivos:

Objetivo general: Analizar la relación entre el peso de las mercancías exportadas y sus costos asociados (valor FOB y fletes) en las exportaciones colombianas de junio de 2026, mediante técnicas de estadística inferencial.

Objetivos específicos:

1. Caracterizar estadísticamente las variables de valor, peso y costos de las exportaciones seleccionadas.
2. Evaluar el cumplimiento del supuesto de normalidad de la variable Valor FOB (USD), antes y después del tratamiento de valores atípicos.
3. Determinar, mediante un modelo de regresión lineal simple, la relación entre el peso neto de la mercancía y su valor FOB.
4. Comparar los costos de flete asociados a las exportaciones según el modo de transporte utilizado.

Este análisis resulta de interés para empresas exportadoras que buscan dimensionar sus costos logísticos en función del peso de sus productos, así como para actores del sector público interesados en identificar patrones de eficiencia en el comercio exterior colombiano. El estudio se limita a las exportaciones registradas por la DIAN durante el mes de junio de 2026, y se desarrolla sobre una muestra aleatoria de 1.500 registros, de la cual se excluyeron 394 valores atípicos (26.27 %) mediante el método del rango intercuartílico (IQR), aplicado sobre las variables Valor FOB (USD), Peso Neto (Kg) y Cant. Unidades, obteniendo una muestra final de 1.106 registros para el análisis.

2. Marco teórico

Distribuciones de probabilidad y supuesto de normalidad

Muchas pruebas estadísticas paramétricas (como la prueba t o el ANOVA) asumen que la variable analizada sigue una distribución normal. Para verificar este supuesto se utilizó la prueba de **Shapiro-Wilk** [4], cuyo estadístico W se calcula como:

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)}\right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

donde $x_{(i)}$ son los valores ordenados de la muestra y a_i son coeficientes derivados de los momentos esperados de una distribución normal. Valores de W cercanos a 1 indican mayor compatibilidad con la normalidad. En este proyecto, la prueba aplicada sobre *Valor FOB (USD)* arrojó $W = 0,6277$ ($p < 0,001$), rechazando el supuesto de normalidad. Esto condiciona la elección de las pruebas inferenciales posteriores, que deben ser de tipo **no paramétrico**.

Lógica de las pruebas de hipótesis

Toda prueba de hipótesis contrasta una hipótesis nula (H_0), que representa la ausencia de efecto o diferencia, contra una hipótesis alternativa (H_1). Se define un nivel de significancia α (en este estudio, $\alpha = 0,05$) como el umbral máximo de probabilidad aceptable de rechazar H_0 siendo esta verdadera (error tipo I). El **valor** p obtenido se compara contra α : si $p < \alpha$, se rechaza H_0 ; de lo contrario, no se rechaza.

Prueba de Kruskal-Wallis

La prueba de Kruskal-Wallis [5] es el equivalente no paramétrico del ANOVA de un factor. Se utiliza para comparar si más de dos grupos independientes provienen de la misma distribución, sin asumir normalidad. En lugar de trabajar con los valores originales, la prueba convierte todas las observaciones en rangos y calcula el estadístico:

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1)$$

donde k es el número de grupos, N el tamaño total de la muestra, n_i el tamaño del grupo i , y R_i la suma de rangos del grupo i . Bajo H_0 , el estadístico H sigue aproximadamente una distribución chi-cuadrado con $k - 1$ grados de libertad. Se eligió esta prueba, en lugar de ANOVA, debido a que *Valor FOB (USD)* no cumple el supuesto de normalidad.

Correlación de Spearman

El coeficiente de correlación de Spearman [6], denotado ρ , mide la fuerza y dirección de una relación **monótona** entre dos variables cuantitativas, sin asumir linealidad ni normalidad. Se calcula aplicando la fórmula de Pearson sobre los rangos de las observaciones:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

donde d_i es la diferencia entre los rangos de cada par de observaciones y n el número de observaciones. El coeficiente toma valores entre -1 y 1 ; valores cercanos a los extremos indican una relación monótona fuerte (positiva o negativa), mientras que valores cercanos a 0 indican ausencia de relación monótona.

Intervalos de confianza

Un intervalo de confianza (IC) proporciona un rango de valores plausibles para un parámetro poblacional, con un nivel de confianza dado (en este estudio, 95 %). Para el coeficiente de correlación de Spearman, dado que ρ no sigue una distribución normal, el IC se construye mediante la **transformación Z de Fisher**:

$$Z = \operatorname{arctanh}(\rho) = \frac{1}{2} \ln \left(\frac{1 + \rho}{1 - \rho} \right)$$

En la escala Z , el estadístico se distribuye aproximadamente normal con error estándar $\frac{1}{\sqrt{n-3}}$, lo cual permite construir el intervalo $Z \pm 1,96 \times \text{EE}$ y revertirlo a la escala original de ρ mediante la función tangente hiperbólica inversa ($\tanh$).

3. Metodología

Tipo y diseño del estudio

El presente estudio es de tipo **cuantitativo**, con un diseño **no experimental, transversal** (los datos corresponden a un único corte temporal: junio de 2026) y un alcance **descriptivo-correlacional**, ya que busca tanto caracterizar las variables de exportación como establecer relaciones entre ellas.

Descripción del dataset

Los datos utilizados en este estudio provienen de la base de **Estadísticas de Comercio Exterior – Exportaciones**, publicada por la Dirección de Impuestos y Aduanas Nacionales (DIAN), validada y certificada por el Departamento Administrativo Nacional de Estadística (DANE). Corresponde al mes de junio de 2026 y fue descargada el 12 de agosto de 2026 desde la página oficial de estadísticas de comercio exterior de la DIAN.

El archivo original contiene un total de 103.179 registros y 72 variables. Dentro de este conjunto de datos, se identificaron 44 columnas de tipo numérico y 28 columnas de tipo categórico o texto, tal como se resume en la Tabla 1.

Dataset	Filas	Columnas	Columnas numéricas	Columnas categóricas/texto
Original	103179	72	44	28

Figura 1: Resumen del dataset original de exportaciones (junio 2026).

Para determinar qué variables categóricas eran adecuadas para las pruebas de hipótesis del proyecto, se realizó una exploración inicial sobre las variables candidatas: `MODO_TRANSPORTE`, `MODALIDAD_EXPORTACION`, `PAIS_DESTINO_FINAL`, `REGION_DE_ORIGEN` y `TIPO_DE_EMBARQUE`. El objetivo fue evaluar el número de categorías únicas presentes en cada una, ya que un número excesivo de categorías dificulta el análisis estadístico (Tabla 2).

Variable	Categorías únicas
<code>MODO_TRANSPORTE</code>	4
<code>MODALIDAD_EXPORTACION</code>	10
<code>PAIS_DESTINO_FINAL</code>	173
<code>REGION_DE_ORIGEN</code>	31
<code>TIPO_DE_EMBARQUE</code>	3

Figura 2: Número de categorías únicas por variable categórica candidata.

Con base en este análisis, se identificó que la variable `PAIS_DESTINO_FINAL` presenta un total de 173 categorías únicas. Esta alta cardinalidad la hace estadísticamente inviable para

pruebas de hipótesis del tipo chi-cuadrado, ya que generaría una matriz de contingencia demasiado dispersa y sin poder explicativo. Por lo tanto, se decidió excluirla del análisis.

Tras la exclusión de `PAIS_DESTINO_FINAL`, se seleccionaron 11 variables relevantes que orientan el desarrollo de la pregunta de investigación y el modelo de regresión final. Esta selección incluye tanto variables cuantitativas (como valores monetarios y pesos) como variables categóricas de baja cardinalidad. La descripción técnica de cada variable seleccionada se presenta en la Tabla 3.

Variable	Tipo	Descripción
Valor FOB (USD)	float64	Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).
Peso Neto (Kg)	float64	Peso neto de la mercancía en kilogramos (sin incluir embalaje).
Peso Bruto (Kg)	float64	Peso bruto de la mercancía en kilogramos (incluyendo embalaje).
Vlr. Serie Nal (USD)	float64	Valor total de la serie agregada nacional en dólares.
Fletes (USD)	float64	Valor de los fletes internacionales en dólares.
Seguros (USD)	float64	Valor de los seguros internacionales en dólares.
Cant. Unidades	float64	Cantidad de unidades físicas de la mercancía.
Modo Transporte	object	Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).
Modalidad	object	Modalidad de exportación (definitiva, temporal, etc.).
Región Origen	object	Región de origen de la mercancía en Colombia.
Tipo Embarque	object	Tipo de embarque (único, consolidado, etc.).

Figura 3: Variables seleccionadas del dataset de exportaciones.

Proceso de limpieza y muestreo

Dado el volumen del dataset filtrado y con el fin de optimizar los recursos computacionales, se optó por trabajar con una muestra aleatoria simple de 1.500 registros. Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados.

Una vez extraída la muestra, se aplicó un procedimiento sistemático para detectar y excluir valores atípicos (outliers) sobre tres variables cuantitativas: *Valor FOB (USD)*, *Peso Neto (Kg)* y *Cant. Unidades*. Se utilizó el método del rango intercuartílico (IQR), considerando como outlier todo valor por debajo de $Q_1 - 1,5 \times IQR$ o por encima de $Q_3 + 1,5 \times IQR$ en al menos una de las tres variables. La Tabla 4 resume los estadísticos clave de este procedimiento, detallados por variable, así como el total combinado.

Variable	Outliers detectados	Porcentaje	Límite inferior	Límite superior	Q1	Q3	IQR
Valor FOB (USD)	223	14.87%	-16258.31	28163.49	399.86	11505.31	11105.45
Peso Neto (Kg)	267	17.80%	-2968.16	5018.47	26.82	2023.48	1996.66
Cant. Unidades	269	17.93%	-6177.74	10413.56	44.00	4191.83	4147.83
TOTAL (unión de las 3 variables)	394	26.27%	-	-	-	-	-

Figura 4: Estadísticos de detección de outliers sobre la muestra (n=1500), por variable.

En total se detectaron **394 registros atípicos** (26.27 % de la muestra). Estos registros se excluyeron para obtener una muestra depurada de **1.106** registros, sobre la cual se realizó el análisis exploratorio y las pruebas inferenciales. La Tabla 5 compara las dimensiones de la muestra inicial (con outliers) y la muestra final sin outliers.

Dataset	Filas	Columnas
Muestra inicial (seed 42)	1500	11
Muestra sin outliers	1106	11

Figura 5: Comparación de dimensiones: muestra inicial vs. muestra sin outliers.

A modo de ejemplo tangible, la Tabla 6 presenta las primeras cinco filas de la muestra de trabajo ya depurada.

Valor FOB (USD)	Peso Neto (Kg)	Peso Bruto (Kg)	Vir. Serie Nal (USD)	Fletes (USD)	Seguros (USD)	Cant. Unidades	Modo Transporte	Modalidad	Región Origen	Tipo Embarque
1932.880000	722.540000	743.930000	0.000000	0.000000	0.000000	722.540000	Marítimo	Exportación definitiva de mercancías de fabricación o producción nacional	ANTIOQUIA	Unico
2797.250000	558.000000	573.930000	2412.380000	215.880000	0.000000	9.000000	Terrestre (carretero)	Las demás exportaciones definitivas no incluidas como exportaciones definitivas	CALDAS	Unico
530.910000	23.260000	28.750000	0.000000	0.000000	0.000000	23.260000	Terrestre (carretero)	Exportación definitiva de mercancías de fabricación o producción nacional	ANTIOQUIA	Unico
280.000000	63.550000	64.650000	0.000000	0.000000	0.000000	63.550000	Terrestre (carretero)	Exportación definitiva de mercancías de fabricación o producción nacional	NORTE DE SANTANDER	Unico
715.590000	224.710000	229.300000	0.000000	0.000000	0.000000	224.710000	Aéreo	Exportación definitiva de mercancías de fabricación o producción nacional	CUNDINAMARCA	Unico

Figura 6: Primeras 5 filas de la muestra final (sin outliers).

Técnicas inferenciales aplicadas

La Tabla 1 resume las técnicas inferenciales seleccionadas para este avance y su justificación, derivada directamente del supuesto de normalidad evaluado en la sección de Análisis exploratorio.

Técnica	Variables	Justificación
Shapiro-Wilk	Valor FOB (USD)	Verificar supuesto de normalidad antes de elegir pruebas paramétricas o no paramétricas.
Kruskal-Wallis	Valor FOB (USD) vs. Modo Transporte	Comparación de más de 2 grupos independientes; no asume normalidad, a diferencia de ANOVA.
Correlación de Spearman	Peso Neto (Kg) vs. Valor FOB (USD)	Mide relación monótona entre variables cuantitativas sin asumir linealidad ni normalidad.

Cuadro 1: Técnicas inferenciales aplicadas y su justificación.

Herramientas computacionales

El análisis se desarrolló en **Python**, utilizando las siguientes librerías: **pandas** para manipulación de datos, **scipy.stats** para las pruebas estadísticas (**shapiro**, **kruskal**, **spearmanr**), **numpy** para el cálculo del intervalo de confianza mediante la transformación de Fisher, **matplotlib** y **seaborn** para las visualizaciones, y **dataframe_image** para la exportación de tablas como imágenes incluidas en este documento.

4. Análisis exploratorio

A partir de la muestra depurada descrita en la sección de Metodología, se llevó a cabo un análisis exploratorio que incluye la estadística descriptiva de las variables cuantitativas, visualizaciones comparativas antes y después del tratamiento de outliers, y la verificación formal del supuesto de normalidad, como base para las pruebas inferenciales presentadas en la siguiente sección.

4.1. Estadística descriptiva

Para dimensionar el efecto del tratamiento de outliers sobre las variables cuantitativas, se calcularon los estadísticos descriptivos (media, mediana, desviación estándar, mínimo, máximo y asimetría) tanto para la muestra con outliers (1.500 registros) como para la muestra depurada (1.106 registros). La Tabla 7 presenta los resultados sobre la muestra con outliers, mientras que la Tabla 8 presenta los mismos estadísticos sobre la muestra sin outliers.

	count	mean	std	min	25%	50%	75%	max	Asimetría
Valor FOB (USD)	1500.0	52720.09	916701.21	0.06	399.86	2023.00	11505.31	34800615.03	36.49
Peso Neto (Kg)	1500.0	60707.41	1905363.94	0.01	26.82	209.50	2023.48	73538808.00	38.29
Peso Bruto (Kg)	1500.0	61142.05	1905431.48	0.01	30.28	238.88	2220.53	73538808.00	38.29
Vir. Serie Nal (USD)	1500.0	8157.61	69687.32	0.00	0.00	0.00	328.46	1696214.53	17.76
Fletes (USD)	1500.0	264.57	1426.91	0.00	0.00	0.00	10.97	35499.84	15.29
Seguros (USD)	1500.0	17.18	376.23	0.00	0.00	0.00	0.00	14249.42	36.31
Cant. Unidades	1500.0	23548.58	211590.49	0.01	44.00	326.92	4191.83	6046090.00	20.75

Figura 7: Estadística descriptiva de las variables numéricas – muestra con outliers.

	count	mean	std	min	25%	50%	75%	max	Asimetría
Valor FOB (USD)	1106.0	2860.39	4675.58	0.06	235.24	959.00	2951.61	27944.90	2.73
Peso Neto (Kg)	1106.0	428.85	842.60	0.01	14.84	83.00	378.75	4922.68	2.95
Peso Bruto (Kg)	1106.0	475.57	917.26	0.01	16.59	91.31	437.20	6211.00	2.93
Vir. Serie Nal (USD)	1106.0	738.97	2347.68	0.00	0.00	0.00	78.41	20682.63	4.78
Fletes (USD)	1106.0	68.08	300.16	0.00	0.00	0.00	4.24	4178.69	7.99
Seguros (USD)	1106.0	1.37	9.65	0.00	0.00	0.00	0.00	147.94	10.60
Cant. Unidades	1106.0	802.81	1599.73	0.01	25.00	140.50	718.50	10000.00	3.19

Figura 8: Estadística descriptiva de las variables numéricas – muestra sin outliers.

Al ampliar el criterio IQR a tres variables (Valor FOB, Peso Neto y Cant. Unidades), la mejora en la forma de la distribución es considerable. La asimetría de *Valor FOB (USD)* se

reduce de **36.49** a **2.73**, y la de *Peso Neto (Kg)* de **38.29** a **2.95**. La desviación estándar de *Valor FOB (USD)* cae de 916,701,21 a 4,675,58, quedando en un orden de magnitud comparable al de su media (2,860,39).

4.2. Visualizaciones

Las Figuras 9–12 presentan los histogramas de *Valor FOB (USD)* y *Peso Neto (Kg)*, antes y después de la exclusión de outliers.




Figura 9: Distribución de Valor FOB (USD) – muestra con outliers.




Figura 10: Distribución de Valor FOB (USD) – muestra sin outliers.




Figura 11: Distribución de Peso Neto (Kg) – muestra con outliers.




Figura 12: Distribución de Peso Neto (Kg) – muestra sin outliers.

Los histogramas con outliers (Figuras 9 y 11) muestran prácticamente la totalidad de las observaciones concentradas en una única barra cercana a cero. Al excluir los outliers (Figuras 10 y 12), ambas distribuciones recuperan una forma interpretable: una alta concentración de exportaciones de bajo valor y peso, seguida de una cola derecha decreciente – forma característica de una distribución log-normal, que respalda la recomendación de aplicar una transformación logarítmica en el modelo de regresión del Proyecto Final.

4.3. Verificación de normalidad

Como evidencia inicial del problema de normalidad, la Figura 13 muestra el gráfico Q-Q de la muestra de 1.500 registros antes de excluir valores atípicos.




Figura 13: Gráfico Q-Q para la muestra inicial (con outliers).

Tras la exclusión de los 394 outliers, se aplicó la prueba de Shapiro-Wilk sobre la muestra depurada de 1.106 registros:

- Estadístico de prueba (W): **0.6277**
- Valor p : **<0.001**

Dado que $p < \alpha = 0,05$, se **rechaza la hipótesis nula: Valor FOB (USD)**, incluso tras el tratamiento de outliers, **no sigue una distribución normal**. El gráfico Q-Q de la Figura 14 respalda este resultado: el punto extremo aislado desaparece, pero los cuantiles siguen desviándose de forma sistemática de la línea de referencia, coherente con la asimetría residual de **2.73**. Este resultado justifica el uso de pruebas **no paramétricas** (Kruskal-Wallis y correlación de Spearman) en la siguiente sección.




Figura 14: Gráfico Q-Q para la muestra sin outliers.

5. Resultados

5.1. Prueba 1: Kruskal-Wallis – Valor FOB según Modo de Transporte

Previo a la prueba, se verificó la distribución de observaciones por categoría de *Modo Transporte* en la muestra depurada (Tabla 15).

Modo Transporte	Frecuencia
Aéreo	547
Marítimo	414
Terrestre (carretero)	143
Instalaciones Fijas	2

Figura 15: Conteo de observaciones por Modo de Transporte (muestra sin outliers).

Se observa un marcado desbalance: los modos Aéreo (547) y Marítimo (414) concentran la gran mayoría de las observaciones, mientras que *Instalaciones Fijas* cuenta con apenas 2 registros. Esta limitación se tiene en cuenta al interpretar el resultado, ya que un grupo con tan pocas observaciones aporta escasa información estadística, aunque no invalida la prueba.

Se aplicó la prueba de Kruskal-Wallis para contrastar si el *Valor FOB (USD)* difiere entre los cuatro modos de transporte. Los resultados se presentan en la Tabla 16.

Elemento	Valor
H0	Las medianas de Valor FOB son iguales entre modos de transporte
H1	Al menos un modo de transporte difiere en Valor FOB
Estadístico (H)	87.3240
Grados de libertad	3
Valor p	< 0.001
Nivel de significancia (alfa)	0.05
Decisión	SE RECHAZA H0. Existe evidencia estadística de que al menos un modo de transporte difiere en Valor FOB.

Figura 16: Resultados de la prueba de Kruskal-Wallis.

Con un estadístico $H = 87,3240$ ($gl = 3$) y un valor $p < 0,001$, se **rechaza la hipótesis nula**: existe evidencia estadística sólida de que al menos un modo de transporte difiere de los demás en términos de Valor FOB. La Figura 17 ilustra esta diferencia mediante un diagrama de cajas por grupo.




Figura 17: Valor FOB (USD) por Modo de Transporte.

El boxplot muestra que *Marítimo* presenta la mediana más alta, seguido de *Terrestre* y *Aéreo*, aunque los tres grupos conservan una dispersión interna considerable, con numerosos valores por encima de sus propios bigotes – consistente con la asimetría residual de la variable incluso tras el tratamiento global de outliers. El grupo *Instalaciones Fijas*, al contar con solo 2 observaciones, no presenta puntos marcados como atípicos, lo cual es resultado directo de su tamaño reducido y no de una menor variabilidad real.

5.2. Prueba 2: Correlación de Spearman – Peso Neto y Valor FOB

Se calculó la correlación de Spearman entre *Peso Neto (Kg)* y *Valor FOB (USD)* sobre la muestra depurada de 1.106 registros. Los resultados se presentan en la Tabla 18.

Elemento	Valor
H0	No existe correlación monótona entre Peso Neto y Valor FOB ($\rho=0$)
H1	Existe correlación monótona entre Peso Neto y Valor FOB ($\rho\neq 0$)
Coefficiente de Spearman (ρ)	0.7597
IC 95% para ρ	[0.7336, 0.7836]
Valor p	< 0.001
Nivel de significancia (alfa)	0.05
Decisión	SE RECHAZA H0. Existe evidencia estadística de correlación entre Peso Neto y Valor FOB.

Figura 18: Resultados de la correlación de Spearman entre Peso Neto y Valor FOB.

Se obtuvo un coeficiente $\rho = 0,7597$, con un intervalo de confianza al 95 % de [0,7336, 0,7836] y un valor $p < 0,001$. Dado que el intervalo no incluye el cero y el valor p es inferior a $\alpha = 0,05$, se **rechaza la hipótesis nula**: existe una correlación monótona positiva, fuerte y estadísticamente significativa entre el peso neto de la mercancía y su valor FOB. La Figura 19 presenta el diagrama de dispersión correspondiente.




Figura 19: Relación entre Peso Neto (Kg) y Valor FOB (USD).

El diagrama de dispersión muestra una tendencia creciente consistente con el coeficiente obtenido: a mayor peso neto, el valor FOB tiende a ser mayor. Sin embargo, se observa

una dispersión considerable, especialmente en los pesos bajos (cerca de 0–500 kg), donde coexisten exportaciones de muy bajo y muy alto valor – un patrón coherente con mercancías de alto valor unitario y bajo peso (por ejemplo, productos electrónicos o flores) que se mezclan con mercancías de bajo valor y peso similar. Este hallazgo refuerza la decisión, planteada en el Análisis exploratorio, de aplicar una transformación logarítmica a *Valor FOB (USD)* antes de construir el modelo de regresión lineal en el Proyecto Final.

6. Discusión

Referencias

Referencias

- [1] Dirección de Impuestos y Aduanas Nacionales - DIAN. (2026). *Estadísticas de comercio exterior - Exportaciones (junio 2026)*. Recuperado de <https://www.dian.gov.co/dian/cifras/Paginas/Bases-Estadisticas-de-Comercio-Exterior-Importaciones-y-Exportaciones.aspx>
- [2] Departamento Administrativo Nacional de Estadística - DANE. (2026). *Comercio exterior: Metodología y validación de estadísticas de exportaciones*. Recuperado de <https://www.dane.gov.co>
- [3] Montgomery, D. C., & Runger, G. C. (2018). *Applied statistics and probability for engineers* (7th ed.). Wiley.
- [4] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3/4), 591–611. <https://doi.org/10.2307/2333709>
- [5] Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621. <https://doi.org/10.1080/01621459.1952.10483441>
- [6] Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101. <https://doi.org/10.2307/1412159>

A. Apéndice: Código fuente

```
1 # =====
2 # Proyecto Integrador - Analítica Descriptiva II
3 # Avance 1: EDA - Exportaciones Colombia (DIAN, Junio 2026)
4 # Fuente: https://www.dian.gov.co/dian/cifras/Paginas/
   EstadisticasComEx.aspx
5 # Fecha de descarga del archivo: 12/08/2026
6 # Equipo: Angie Montero, Michael Baquero
7 # =====
8
9 # Importe de librerías
10 import numpy as np
11 from scipy.stats import spearmanr
12 import os
13 import pandas as pd
14 import dataframe_image as dfi
15 import matplotlib.pyplot as plt
16 import seaborn as sns
17 from scipy.stats import shapiro, probplot, skew, kruskal
18
19
20 def exportar_imagen(path):
21     """
22     Elimina la imagen existente en 'path' (si existe) antes de
23     generar
24     la nueva. Evita que queden versiones desactualizadas en Doc/
25     anexos/
26     cuando se vuelve a correr el script tras un cambio.
27     """
28     if os.path.exists(path):
29         os.remove(path)
30
31 # -----
32 # Descripción del dataset
33 # -----
34
35 # Lectura del documento
36 df = pd.read_excel("Data/06_Exportaciones_2026_Junio.xlsx")
37
38 # Visualización inicial del dataframe
39 print('Visualización de primeras filas:\n', df.head(5))
40 print('\nVisualización de las dimensiones: ', df.shape)
41 print(df.info())
42
43 # Exportación: resumen del dataset ORIGINAL
```

```

43 resumen_original = pd.DataFrame({
44     "Dataset": ["Original"],
45     "Filas": [df.shape[0]],
46     "Columnas": [df.shape[1]],
47     "Columnas numéricas": [df.select_dtypes(include="number").shape
48         [1]],
49     "Columnas categóricas/texto": [df.select_dtypes(include="object")
50         .shape[1]]
51 })
52 exportar_imagen("Doc/anexos/tabla_resumen_original.png")
53 dfi.export(resumen_original.style.hide(axis='index'),
54     "Doc/anexos/tabla_resumen_original.png")
55
56 # Exploración preliminar de variables categóricas candidatas
57 categoricas_candidatas = [
58     "MODO_TRANSPORTE",
59     "MODALIDAD_EXPORTACION",
60     "PAIS_DESTINO_FINAL",
61     "REGION_DE_ORIGEN",
62     "TIPO_DE_EMBARQUE"
63 ]
64
65 for col in categoricas_candidatas:
66     print(col, "->", df[col].nunique(), "categorías únicas")
67
68 # Exportación: número de categorías únicas por variable categórica
69     candidata
70 resumen_categoricas = pd.DataFrame({
71     "Variable": categoricas_candidatas,
72     "Categorías únicas": [df[col].nunique() for col in
73         categoricas_candidatas]
74 })
75 exportar_imagen("Doc/anexos/tabla_categoricas.png")
76 dfi.export(resumen_categoricas.style.hide(axis='index'),
77     "Doc/anexos/tabla_categoricas.png")
78
79 # Filtro de columnas relevantes (se excluye PAIS_DESTINO_FINAL)
80 columnas_relevantes = [
81     "VALOR_FOB_USD",
82     "PESO_NETO_KGS",
83     "PESO_BRUTO_KGS",
84     "VLR_SERIE_AGREGADO_NAL_USD",
85     "VALOR_SERIE_FLETES_USD",
86     "VALOR_SERIE_SEGUROS_USD",
87     "CANTIDAD_UNIDADES_FISICAS",
88     "MODO_TRANSPORTE",
89     "MODALIDAD_EXPORTACION",
90     "REGION_DE_ORIGEN",
91     "TIPO_DE_EMBARQUE"

```

```

87 ]
88 df_filtrado = df[columnas_relevantes]
89
90 # Renombres para nombres cortos y legibles
91 renombres = {
92     "VALOR_FOB_USD": "Valor FOB (USD)",
93     "PESO_NETO_KGS": "Peso Neto (Kg)",
94     "PESO_BRUTO_KGS": "Peso Bruto (Kg)",
95     "VLR_SERIE_AGREGADO_NAL_USD": "Vlr. Serie Nal (USD)",
96     "VALOR_SERIE_FLETES_USD": "Fletes (USD)",
97     "VALOR_SERIE_SEGUROS_USD": "Seguros (USD)",
98     "CANTIDAD_UNIDADES_FISICAS": "Cant. Unidades",
99     "MODO_TRANSPORTE": "Modo Transporte",
100     "MODALIDAD_EXPORTACION": "Modalidad",
101     "REGION_DE_ORIGEN": "Región Origen",
102     "TIPO_DE_EMBARQUE": "Tipo Embarque"
103 }
104 df_filtrado = df_filtrado.rename(columns=renombres)
105
106 # Diccionario con descripciones
107 descripciones = {
108     "VALOR_FOB_USD": "Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).",
109     "PESO_NETO_KGS": "Peso neto de la mercancía en kilogramos (sin incluir embalaje).",
110     "PESO_BRUTO_KGS": "Peso bruto de la mercancía en kilogramos (incluyendo embalaje).",
111     "VLR_SERIE_AGREGADO_NAL_USD": "Valor total de la serie agregada nacional en dólares.",
112     "VALOR_SERIE_FLETES_USD": "Valor de los fletes internacionales en dólares.",
113     "VALOR_SERIE_SEGUROS_USD": "Valor de los seguros internacionales en dólares.",
114     "CANTIDAD_UNIDADES_FISICAS": "Cantidad de unidades físicas de la mercancía.",
115     "MODO_TRANSPORTE": "Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).",
116     "MODALIDAD_EXPORTACION": "Modalidad de exportación (definitiva, temporal, etc.).",
117     "REGION_DE_ORIGEN": "Región de origen de la mercancía en Colombia.",
118     "TIPO_DE_EMBARQUE": "Tipo de embarque (único, consolidado, etc.)."
119 }
120
121 # Exportación: tabla de variables seleccionadas
122 tabla_variables = pd.DataFrame({
123     "Variable": [renombres[col] for col in columnas_relevantes],

```

```

124     "Tipo": [str(df_filtrado[col].dtype) for col in df_filtrado.
           columns],
125     "Descripción": [descripciones[col] for col in columnas_relevantes
           ]
126 })
127 exportar_imagen("Doc/anexos/tabla_variables_seleccionadas.png")
128 dfi.export(tabla_variables.style.hide(axis='index'),
129            "Doc/anexos/tabla_variables_seleccionadas.png")
130
131 # Validación de valores nulos
132 print('\nVisualización de valores nulos:\n', df_filtrado.isnull().sum
      ())
133
134 # Muestreo inicial (sobre el dataset filtrado)
135 df_muestra = df_filtrado.sample(n=1500, random_state=42).reset_index(
      drop=True)
136 print(f"\nMuestra obtenida: {df_muestra.shape[0]} filas")
137
138 # Q-Q plot de la muestra con outliers.
139 # Se genera como evidencia visual del problema de no normalidad,
      antes
140 # de aplicar el tratamiento de outliers.
141 plt.figure(figsize=(8, 6))
142 probplot(df_muestra['Valor FOB (USD)'].dropna(), dist="norm", plot=
      plt)
143 plt.title('Q-Q plot - Muestra (con outliers)', fontsize=14)
144 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
145 plt.ylabel('Cuantiles muestrales', fontsize=12)
146 plt.grid(alpha=0.4)
147 plt.tight_layout()
148 exportar_imagen('Doc/anexos/qqplot_muestra_con_outliers.png')
149 plt.savefig('Doc/anexos/qqplot_muestra_con_outliers.png', dpi=300)
150 plt.close()
151
152 # Detección de outliers sobre la muestra (método IQR), aplicado a las
153 # tres variables cuantitativas con mayor cardinalidad de valores
154 # extremos: Valor FOB (USD), Peso Neto (Kg) y Cant. Unidades. Una
      fila
155 # se considera atípica si lo es en AL MENOS UNA de estas tres
      variables
156 # (unión de máscaras), de modo que la muestra depurada quede libre de
157 # outliers en las tres a la vez.
158 variables_outlier = ["Valor FOB (USD)", "Peso Neto (Kg)", "Cant.
      Unidades"]
159
160 outliers_mask = pd.Series(False, index=df_muestra.index)
161 resumen_por_variable = []
162

```

```

163 for var in variables_outlier:
164     Q1 = df_muestra[var].quantile(0.25)
165     Q3 = df_muestra[var].quantile(0.75)
166     IQR = Q3 - Q1
167     lower_bound = Q1 - 1.5 * IQR
168     upper_bound = Q3 + 1.5 * IQR
169
170     var_mask = (df_muestra[var] < lower_bound) | (
171         df_muestra[var] > upper_bound)
172     outliers_mask = outliers_mask | var_mask
173
174     resumen_por_variable.append({
175         "Variable": var,
176         "Outliers detectados": int(var_mask.sum()),
177         "Porcentaje": f"{100 * var_mask.sum() / len(df_muestra):.2f}%",
178         "Límite inferior": f"{lower_bound:.2f}",
179         "Límite superior": f"{upper_bound:.2f}",
180         "Q1": f"{Q1:.2f}",
181         "Q3": f"{Q3:.2f}",
182         "IQR": f"{IQR:.2f}"
183     })
184
185 num_outliers = int(outliers_mask.sum())
186 total_rows = len(df_muestra)
187 pct_outliers = 100 * num_outliers / total_rows
188
189 # Exportación: tabla resumen de la detección de outliers, con una
190 # fila
191 # por variable analizada y una fila de totales (unión de las tres).
192 tabla_outliers = pd.DataFrame(resumen_por_variable)
193 tabla_outliers = pd.concat([
194     tabla_outliers,
195     pd.DataFrame([
196         "Variable": "TOTAL (unión de las 3 variables)",
197         "Outliers detectados": num_outliers,
198         "Porcentaje": f"{pct_outliers:.2f}%",
199         "Límite inferior": "-",
200         "Límite superior": "-",
201         "Q1": "-",
202         "Q3": "-",
203         "IQR": "-"
204     ]), ignore_index=True)
205
206 exportar_imagen("Doc/anexos/tabla_outliers_muestra.png")
207 dfi.export(tabla_outliers.style.hide(axis='index'),
208             "Doc/anexos/tabla_outliers_muestra.png")

```

```

209
210 print("\n--- Resumen de outliers (sobre la muestra) ---")
211 print(tabla_outliers.to_string(index=False))
212
213 # Exclusión de outliers para obtener la muestra de trabajo definitiva
214 df_muestra_clean = df_muestra[~outliers_mask].copy()
215 print(f"\nFilas después de excluir outliers: {len(df_muestra_clean)}"
      )
216
217 # Exportación: comparación de dimensiones muestra inicial vs. sin
      outliers
218 resumen_muestra = pd.DataFrame({
219     "Dataset": ["Muestra inicial (seed 42)", "Muestra sin outliers"],
220     "Filas": [df_muestra.shape[0], df_muestra_clean.shape[0]],
221     "Columnas": [df_muestra.shape[1], df_muestra_clean.shape[1]]
222 })
223 exportar_imagen("Doc/anexos/tabla_dimensiones_muestra.png")
224 dfi.export(resumen_muestra.style.hide(axis='index'),
225            "Doc/anexos/tabla_dimensiones_muestra.png")
226
227 # Exportación: primeras filas de la muestra limpia, redondeada a 2
228 # decimales. Se oculta el índice para mantener el mismo estilo visual
229 # que las demás tablas exportadas.
230 muestra_head = df_muestra_clean.head(5).round(2)
231 exportar_imagen("Doc/anexos/tabla_muestra_head.png")
232 dfi.export(muestra_head.style.hide(axis='index'),
233            "Doc/anexos/tabla_muestra_head.png")
234
235
236 # -----
237 # Análisis exploratorio: estadística descriptiva
238 # -----
239 # Se comparan df_muestra (1500 filas, con outliers) y
      df_muestra_clean
240 # (sin outliers en Valor FOB, Peso Neto y Cant. Unidades) para
241 # evidenciar el efecto del tratamiento de outliers sobre la forma de
242 # la distribución. Ambas provienen de la misma muestra base, por lo
243 # que el único factor que cambia entre ellas es el tratamiento de
244 # valores atípicos, no el tamaño muestral.
245
246 columnas_numericas = df_muestra.select_dtypes(
247     include='number').columns.tolist()
248 print(f"Variables numéricas: {columnas_numericas}")
249
250 # Estadística descriptiva de las variables numéricas: se calcula con
251 # describe() y se agrega la asimetría (skew), que describe() no
      incluye.

```

```

252 estadisticos_con_outliers = df_muestra[columnas_numericas].describe()
    .T
253 estadisticos_con_outliers["Asimetría"] = df_muestra[
    columnas_numericas].apply(
254     skew)
255 estadisticos_con_outliers = estadisticos_con_outliers.round(2)
256 print("\nEstadística descriptiva - muestra con outliers:\n",
257     estadisticos_con_outliers)
258
259 exportar_imagen("Doc/anexos/tabla_estadisticos_con_outliers.png")
260 dfi.export(estadisticos_con_outliers,
261     "Doc/anexos/tabla_estadisticos_con_outliers.png")
262
263 estadisticos_sin_outliers = df_muestra_clean[columnas_numericas].
    describe().T
264 estadisticos_sin_outliers["Asimetría"] = df_muestra_clean[
    columnas_numericas].apply(
265     skew)
266 estadisticos_sin_outliers = estadisticos_sin_outliers.round(2)
267 print("\nEstadística descriptiva - muestra sin outliers:\n",
268     estadisticos_sin_outliers)
269
270 exportar_imagen("Doc/anexos/tabla_estadisticos_sin_outliers.png")
271 dfi.export(estadisticos_sin_outliers,
272     "Doc/anexos/tabla_estadisticos_sin_outliers.png")
273
274
275 # -----
276 # Análisis exploratorio: visualizaciones
277 # -----
278
279 # Histograma de Valor FOB, con y sin outliers.
280 plt.figure(figsize=(8, 5))
281 sns.histplot(df_muestra["Valor FOB (USD)"].dropna(), kde=True, color=
    "#4C72B0")
282 plt.title("Valor FOB (USD) - Muestra con outliers", fontsize=13)
283 plt.xlabel("Valor FOB (USD)")
284 plt.ylabel("Frecuencia")
285 plt.tight_layout()
286 exportar_imagen("Doc/anexos/histograma_valor_fob_con_outliers.png")
287 plt.savefig("Doc/anexos/histograma_valor_fob_con_outliers.png", dpi
    =300)
288 plt.close()
289
290 plt.figure(figsize=(8, 5))
291 sns.histplot(
292     df_muestra_clean["Valor FOB (USD)"].dropna(), kde=True, color="#4
    C72B0")

```

```

293 plt.title("Valor FOB (USD) - Muestra sin outliers", fontsize=13)
294 plt.xlabel("Valor FOB (USD)")
295 plt.ylabel("Frecuencia")
296 plt.tight_layout()
297 exportar_imagen("Doc/anexos/histograma_valor_fob_sin_outliers.png")
298 plt.savefig("Doc/anexos/histograma_valor_fob_sin_outliers.png", dpi
    =300)
299 plt.close()
300
301 # Histograma de Peso Neto, con y sin outliers.
302 plt.figure(figsize=(8, 5))
303 sns.histplot(df_muestra["Peso Neto (Kg)"].dropna(), kde=True, color="#
    #4C72B0")
304 plt.title("Peso Neto (Kg) - Muestra con outliers", fontsize=13)
305 plt.xlabel("Peso Neto (Kg)")
306 plt.ylabel("Frecuencia")
307 plt.tight_layout()
308 exportar_imagen("Doc/anexos/histograma_peso_netto_con_outliers.png")
309 plt.savefig("Doc/anexos/histograma_peso_netto_con_outliers.png", dpi
    =300)
310 plt.close()
311
312 plt.figure(figsize=(8, 5))
313 sns.histplot(
314     df_muestra_clean["Peso Neto (Kg)"].dropna(), kde=True, color="#4
        C72B0")
315 plt.title("Peso Neto (Kg) - Muestra sin outliers", fontsize=13)
316 plt.xlabel("Peso Neto (Kg)")
317 plt.ylabel("Frecuencia")
318 plt.tight_layout()
319 exportar_imagen("Doc/anexos/histograma_peso_netto_sin_outliers.png")
320 plt.savefig("Doc/anexos/histograma_peso_netto_sin_outliers.png", dpi
    =300)
321 plt.close()
322
323
324 # -----
325 # Análisis exploratorio: verificación de normalidad
326 # -----
327 # Shapiro-Wilk + gráfico Q-Q para Valor FOB (USD), sobre la muestra
    ya
328 # depurada de outliers (df_muestra_clean), que es la que se usa en el
329 # resto del proyecto.
330
331 variable = df_muestra_clean['Valor FOB (USD)'].dropna()
332 print(f"\nRegistros válidos para la prueba: {len(variable)}")
333
334 estadistico_w, p_valor = shapiro(variable)

```

```

335
336 # Se reporta el valor p redondeado en formato decimal, no en notación
337 # científica. Cuando el valor es extremadamente pequeño (menor a
    0.001),
338 # se reporta como "< 0.001" en vez de un número con muchos ceros,
339 # siguiendo la convención estándar de reporte de pruebas de hipótesis
    .
340 if p_valor < 0.001:
341     p_valor_str = "< 0.001"
342 else:
343     p_valor_str = f"{p_valor:.3f}"
344
345 print(f"\nEstadístico W: {estadistico_w:.4f}")
346 print(f"Valor p: {p_valor_str}")
347
348 alfa = 0.05
349 print(f"\nNivel de significancia (alfa): {alfa}")
350 if p_valor > alfa:
351     conclusion = "NO se rechaza H0. Los datos podrían provenir de una
        distribución normal (no hay evidencia suficiente en contra)."
352 else:
353     conclusion = "SE RECHAZA H0. Existe evidencia estadística
        significativa de que los datos NO siguen una distribución
        normal."
354 print(f"Conclusión: {conclusion}")
355
356 # Gráfico Q-Q de la muestra limpia, como evidencia visual que
357 # complementa el resultado numérico de Shapiro-Wilk.
358 plt.figure(figsize=(8, 6))
359 probplot(variable, dist="norm", plot=plt)
360 plt.title('Q-Q plot - Muestra sin outliers', fontsize=14)
361 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
362 plt.ylabel('Cuantiles muestrales', fontsize=12)
363 plt.grid(alpha=0.4)
364 plt.tight_layout()
365 exportar_imagen('Doc/anexos/qqplot_muestra_sin_outliers.png')
366 plt.savefig('Doc/anexos/qqplot_muestra_sin_outliers.png', dpi=300)
367 plt.close()
368
369 # Conteo de observaciones por categoría de Modo Transporte en la
    muestra limpia.
370 conteo_modos_transporte = df_muestra_clean['Modo Transporte'].
    value_counts(
371 ).reset_index()
372 conteo_modos_transporte.columns = ['Modo Transporte', 'Frecuencia']
373 print("\nConteo por Modo de Transporte (muestra sin outliers):\n",
374     conteo_modos_transporte)
375

```

```

376 exportar_imagen("Doc/anexos/tabla_conteo_modo_transporte.png")
377 dfi.export(conteo_modo_transporte.style.hide(axis='index'),
378            "Doc/anexos/tabla_conteo_modo_transporte.png")
379
380 # Prueba de Kruskal-Wallis: compara si las distribuciones de Valor
    FOB
381 # son iguales entre los grupos de Modo de Transporte, sin asumir
    normalidad
382 grupos_transporte = [
383     grupo['Valor FOB (USD)'].values
384     for _, grupo in df_muestra_clean.groupby('Modo Transporte')
385 ]
386
387 estadistico_h, p_valor_kw = kruskal(*grupos_transporte)
388
389 if p_valor_kw < 0.001:
390     p_valor_kw_str = "< 0.001"
391 else:
392     p_valor_kw_str = f"{p_valor_kw:.3f}"
393
394 alfa = 0.05
395 if p_valor_kw > alfa:
396     conclusion_kw = "NO se rechaza H0. No hay evidencia suficiente de
        diferencias entre los modos de transporte."
397 else:
398     conclusion_kw = "SE RECHAZA H0. Existe evidencia estadística de
        que al menos un modo de transporte difiere en Valor FOB."
399
400 print(f"\nEstadístico H: {estadistico_h:.4f}")
401 print(f"Valor p: {p_valor_kw_str}")
402 print(f"Conclusión: {conclusion_kw}")
403
404 # Exportación: tabla de resultados de la prueba
405 grados_libertad = df_muestra_clean['Modo Transporte'].nunique() - 1
406
407 tabla_kruskal = pd.DataFrame({
408     "Elemento": [
409         "H0",
410         "H1",
411         "Estadístico (H)",
412         "Grados de libertad",
413         "Valor p",
414         "Nivel de significancia (alfa)",
415         "Decisión"
416     ],
417     "Valor": [
418         "Las medianas de Valor FOB son iguales entre modos de
            transporte",

```

```

419         "Al menos un modo de transporte difiere en Valor FOB",
420         f"{estadistico_h:.4f}",
421         f"{grados_libertad}",
422         p_valor_kw_str,
423         f"{alfa}",
424         conclusion_kw
425     ]
426 })
427
428 exportar_imagen("Doc/anexos/tabla_kruskal_valor_fob.png")
429 dfi.export(tabla_kruskal.style.hide(axis='index'),
430            "Doc/anexos/tabla_kruskal_valor_fob.png")
431
432 # Visualización: boxplot de Valor FOB (USD) por Modo de Transporte.
433 plt.figure(figsize=(9, 6))
434 sns.boxplot(data=df_muestra_clean, x='Modo Transporte',
435             y='Valor FOB (USD)', color="#4C72B0")
436 plt.title('Valor FOB (USD) por Modo de Transporte', fontsize=14)
437 plt.xlabel('Modo de Transporte', fontsize=12)
438 plt.ylabel('Valor FOB (USD)', fontsize=12)
439 plt.tight_layout()
440 exportar_imagen('Doc/anexos/boxplot_fob_por_transporte.png')
441 plt.savefig('Doc/anexos/boxplot_fob_por_transporte.png', dpi=300)
442 plt.close()
443
444 # Correlación de Spearman
445 # Relación entre Peso Neto (Kg) y Valor FOB (USD)
446 rho, p_valor_spearman = spearmanr(
447     df_muestra_clean['Peso Neto (Kg)'],
448     df_muestra_clean['Valor FOB (USD)']
449 )
450
451 if p_valor_spearman < 0.001:
452     p_valor_spearman_str = "< 0.001"
453 else:
454     p_valor_spearman_str = f"{p_valor_spearman:.3f}"
455
456 alfa = 0.05
457 if p_valor_spearman > alfa:
458     conclusion_spearman = "NO se rechaza H0. No hay evidencia
459         suficiente de correlación entre Peso Neto y Valor FOB."
460 else:
461     conclusion_spearman = "SE RECHAZA H0. Existe evidencia estadí
462         stica de correlación entre Peso Neto y Valor FOB."
463
464 print(f"\nCoeficiente de Spearman (rho): {rho:.4f}")
465 print(f"Valor p: {p_valor_spearman_str}")
466 print(f"Conclusión: {conclusion_spearman}")

```

```

465
466 # Intervalo de confianza al 95% para rho, mediante la transformación
    Z de Fisher.
467 n = len(df_muestra_clean)
468 # Paso 1: transformar rho a escala Z
469 z_fisher = np.arctanh(rho)
470 error_estandar = 1 / np.sqrt(n - 3)          # Error estándar en
    escala Z
471 z_critico = 1.96                            # Valor crítico para 95%
    de confianza
472
473 z_inferior = z_fisher - z_critico * error_estandar
474 z_superior = z_fisher + z_critico * error_estandar
475
476 ic_inferior = np.tanh(z_inferior)            # Paso 2: revertir a
    escala rho
477 ic_superior = np.tanh(z_superior)
478
479 print(f"IC 95% para rho: [{ic_inferior:.4f}, {ic_superior:.4f}]")
480
481 # Exportación: tabla de resultados de la correlación
482 tabla_spearman = pd.DataFrame({
483     "Elemento": [
484         "H0",
485         "H1",
486         "Coeficiente de Spearman (rho)",
487         "IC 95% para rho",
488         "Valor p",
489         "Nivel de significancia (alfa)",
490         "Decisión"
491     ],
492     "Valor": [
493         "No existe correlación monótona entre Peso Neto y Valor FOB (
            rho=0)",
494         "Existe correlación monótona entre Peso Neto y Valor FOB (rho
            ≠0)",
495         f"{rho:.4f}",
496         f"[{ic_inferior:.4f}, {ic_superior:.4f}]",
497         p_valor_spearman_str,
498         f"{alfa}",
499         conclusion_spearman
500     ]
501 })
502
503 exportar_imagen("Doc/anexos/tabla_spearman_peso_valor.png")
504 dfi.export(tabla_spearman.style.hide(axis='index'),
505             "Doc/anexos/tabla_spearman_peso_valor.png")
506

```

```

507 # Visualización: diagrama de dispersión entre Peso Neto y Valor FOB,
508 # como evidencia visual que complementa el coeficiente numérico.
509 plt.figure(figsize=(8, 6))
510 sns.scatterplot(data=df_muestra_clean, x='Peso Neto (Kg)', y='Valor
    FOB (USD)',
511                alpha=0.5, color="#4C72B0")
512 plt.title('Relación entre Peso Neto y Valor FOB (USD)', fontsize=14)
513 plt.xlabel('Peso Neto (Kg)', fontsize=12)
514 plt.ylabel('Valor FOB (USD)', fontsize=12)
515 plt.tight_layout()
516 exportar_imagen('Doc/anexos/scatter_peso_vs_fob.png')
517 plt.savefig('Doc/anexos/scatter_peso_vs_fob.png', dpi=300)
518 plt.close()
519
520 # -----
521 # Exportación de la muestra limpia para Power BI
522 # -----
523 # Se exporta df_muestra_clean (1.106 registros, sin outliers), que es
524 # la misma muestra usada en las pruebas inferenciales, para que las
525 # visualizaciones de Power BI sean consistentes con los resultados
    del
526 # informe. Gracias a random_state=42, la muestra es reproducible.
527 ruta_bi_xlsx = "Data/muestra_limpia_exportaciones.xlsx"
528
529 df_muestra_clean.to_excel(ruta_bi_xlsx, index=False)
530
531 print(f"\nMuestra limpia exportada: {df_muestra_clean.shape[0]} filas
    , "
532       f"{df_muestra_clean.shape[1]} columnas")

```