

Análisis Exploratorio de Exportaciones Colombianas (Junio 2026)

Angie Montero

Michael Baquero

Analítica Descriptiva II

Unicafam

Agosto 2026

1. Introducción

2. Descripción del dataset

Los datos utilizados en este estudio provienen de la base de **Estadísticas de Comercio Exterior – Exportaciones**, publicada por la Dirección de Impuestos y Aduanas Nacionales (DIAN), validada y certificada por el Departamento Administrativo Nacional de Estadística (DANE). Corresponde al mes de junio de 2026 y fue descargada el 12 de agosto de 2026 desde la página oficial de estadísticas de comercio exterior de la DIAN.

El archivo original contiene un total de 103.179 registros y 72 variables. Dentro de este conjunto de datos, se identificaron 44 columnas de tipo numérico y 28 columnas de tipo categórico o texto, tal como se resume en la Tabla 1.

Dataset	Filas	Columnas	Columnas numéricas	Columnas categóricas/texto
Original	103179	72	44	28

Figura 1: Resumen del dataset original de exportaciones (junio 2026).

Exploración de variables categóricas

Para determinar qué variables categóricas eran adecuadas para las pruebas de hipótesis del proyecto, se realizó una exploración inicial sobre las variables candidatas: `MODO_TRANSPORTE`, `MODALIDAD_EXPORTACION`, `PAIS_DESTINO_FINAL`, `REGION_DE_ORIGEN` y `TIPO_DE_EMBARQUE`. El objetivo fue evaluar el número de categorías únicas presentes en cada una, ya que un número excesivo de categorías dificulta el análisis estadístico (Tabla 2).

Variable	Categorías únicas
<code>MODO_TRANSPORTE</code>	4
<code>MODALIDAD_EXPORTACION</code>	10
<code>PAIS_DESTINO_FINAL</code>	173
<code>REGION_DE_ORIGEN</code>	31
<code>TIPO_DE_EMBARQUE</code>	3

Figura 2: Número de categorías únicas por variable categórica candidata.

Con base en este análisis, se identificó que la variable `PAIS_DESTINO_FINAL` presenta un total de 173 categorías únicas. Esta alta cardinalidad la hace estadísticamente inviable para pruebas de hipótesis del tipo chi-cuadrado, ya que generaría una matriz de contingencia demasiado dispersa y sin poder explicativo. Por lo tanto, se decidió excluirla del análisis.

Selección de variables finales

Tras la exclusión de `PAIS_DESTINO_FINAL`, se seleccionaron 11 variables relevantes que orientan el desarrollo de la pregunta de investigación y el modelo de regresión final. Esta

selección incluye tanto variables cuantitativas (como valores monetarios y pesos) como variables categóricas de baja cardinalidad. La descripción técnica de cada variable seleccionada se presenta en la Tabla 3.

Variable	Tipo	Descripción
Valor FOB (USD)	float64	Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).
Peso Neto (Kg)	float64	Peso neto de la mercancía en kilogramos (sin incluir embalaje).
Peso Bruto (Kg)	float64	Peso bruto de la mercancía en kilogramos (incluyendo embalaje).
Vlr. Serie Nal (USD)	float64	Valor total de la serie agregada nacional en dólares.
Fletes (USD)	float64	Valor de los fletes internacionales en dólares.
Seguros (USD)	float64	Valor de los seguros internacionales en dólares.
Cant. Unidades	float64	Cantidad de unidades físicas de la mercancía.
Modo Transporte	object	Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).
Modalidad	object	Modalidad de exportación (definitiva, temporal, etc.).
Región Origen	object	Región de origen de la mercancía en Colombia.
Tipo Embarque	object	Tipo de embarque (único, consolidado, etc.).

Figura 3: Variables seleccionadas del dataset de exportaciones.

Muestreo y tratamiento de outliers

Dado el volumen del dataset filtrado y con el fin de optimizar los recursos computacionales, se optó por trabajar con una muestra aleatoria simple de 1.500 registros. Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados. Esta reducción evita sobrecargar el modelo de regresión lineal y reduce significativamente los tiempos de ejecución.

Una vez extraída la muestra, se aplicó un procedimiento sistemático para detectar y excluir valores atípicos (outliers) en la variable cuantitativa *Valor FOB (USD)*. Se utilizó el método del rango intercuartílico (IQR), considerando como outlier todo valor por debajo de $Q_1 - 1,5 \times IQR$ o por encima de $Q_3 + 1,5 \times IQR$. La Tabla 4 resume los estadísticos clave de este procedimiento aplicado sobre la muestra de 1.500 registros.

Metrica	Valor
Total de filas en la muestra	1500
Outliers detectados	223
Porcentaje de outliers	14.87%
Limite inferior ($Q1 - 1.5 \cdot IQR$)	-16258.31
Limite superior ($Q3 + 1.5 \cdot IQR$)	28163.49
Valor minimo en la muestra	0.06
Valor maximo en la muestra	34800615.03
Q1	399.86
Q3	11505.31
IQR	11105.45

Figura 4: Estadísticos de detección de outliers sobre la muestra ($n=1500$).

Se detectaron **223 outliers** (14.87% de la muestra), todos ellos correspondientes a valores extremadamente altos, dado que el límite inferior resultó negativo ($-16258,31$) y el valor mínimo observado fue positivo ($0,06$). El valor máximo alcanzó los $34\,800\,615,03$ USD, muy por encima del límite superior de $28\,163,49$ USD. Estos valores atípicos se excluyeron para obtener una muestra depurada de 1.277 registros, sobre la cual se realizó el análisis exploratorio y las pruebas de normalidad.

La Tabla 5 compara las dimensiones de la muestra inicial (con outliers) y la muestra final sin outliers.

Dataset	Filas	Columnas
Muestra inicial (seed 42)	1500	11
Muestra sin outliers	1277	11

Figura 5: Comparación de dimensiones: muestra inicial vs. muestra sin outliers.

A modo de ejemplo tangible, la Tabla 6 presenta las primeras cinco filas de la muestra de trabajo ya depurada. Se puede observar cómo se estructuran los datos de las variables cuantitativas y categóricas seleccionadas para el estudio.

	Valor FOB (USD)	Peso Neto (Kg)	Peso Bruto (Kg)	Vir. Serie Nal (USD)	Fletes (USD)	Seguros (USD)	Cant. Unidades	Modo Transporte	Modalidad	Región Origen	Tipo Embarque
0	1932.88	722.54	743.93	0.00	0.00	0.0	722.54	Marítimo	Exportación definitiva de mercancías de fabric...	ANTIOQUIA	Unico
1	2797.25	558.00	573.93	2412.38	215.88	0.0	9.00	Terrestre (carretero)	Las demás exportaciones definitivas no incluid...	CALDAS	Unico
2	530.91	23.26	28.75	0.00	0.00	0.0	23.26	Terrestre (carretero)	Exportación definitiva de mercancías de fabric...	ANTIOQUIA	Unico
3	280.00	63.55	64.65	0.00	0.00	0.0	63.55	Terrestre (carretero)	Exportación definitiva de mercancías de fabric...	NORTE DE SANTANDER	Unico
4	715.59	224.71	229.30	0.00	0.00	0.0	224.71	Aéreo	Exportación definitiva de mercancías de fabric...	CUNDINAMARCA	Unico

Figura 6: Primeras 5 filas de la muestra final (sin outliers).

3. Análisis exploratorio

3.1. Estadística descriptiva

3.2. Visualizaciones

3.3. Verificación de normalidad

Como evidencia inicial del problema de normalidad, la Figura 7 muestra el gráfico Q-Q de la muestra de 1.500 registros antes de excluir valores atípicos, donde se observa una clara desviación de los puntos respecto a la línea de referencia en los cuantiles superiores, evidenciando la presencia de colas pesadas y valores extremos.




Figura 7: Gráfico Q-Q para la muestra inicial (con outliers).

Tras la exclusión de los 223 outliers detectados mediante el método IQR (ver sección de Muestreo y tratamiento de outliers), se aplicó la prueba de Shapiro-Wilk sobre la muestra depurada de 1.277 registros para evaluar formalmente el supuesto de normalidad de la variable *Valor FOB (USD)*.

Los resultados obtenidos fueron los siguientes:

- Estadístico de prueba (W): **0.6867**
- Valor p : **<0.001**

Dado que el valor p es inferior al nivel de significancia $\alpha = 0,05$, se **rechaza la hipótesis nula**. Existe evidencia estadística de que la variable *Valor FOB (USD)*, incluso tras la exclusión de outliers, **no sigue una distribución normal**. No obstante, vale la pena resaltar la magnitud de la mejora: el estadístico W pasó de **0.0247** (muestra con outliers) a **0.6867** (muestra sin outliers) – un salto sustancial en una escala de 0 a 1, donde 1 representa normalidad perfecta. Esto confirma que la exclusión de outliers tuvo un efecto real y medible

sobre la forma de la distribución, aunque no suficiente para alcanzar significancia estadística de normalidad. El gráfico Q-Q de la Figura 8 respalda visualmente esta mejora: los puntos se aproximan mucho más a la línea diagonal, especialmente en las colas.




Figura 8: Gráfico Q-Q para la muestra sin outliers.

En consecuencia, para el modelo de regresión lineal que se desarrollará en etapas posteriores, se recomienda aplicar una transformación logarítmica a la variable *Valor FOB (USD)* con el fin de aproximar su comportamiento a una distribución normal y cumplir con los supuestos del modelo.

Referencias

Referencias

- [1] Dirección de Impuestos y Aduanas Nacionales - DIAN. (2026). *Estadísticas de comercio exterior - Exportaciones (junio 2026)*. Recuperado de <https://www.dian.gov.co/dian/cifras/Paginas/Bases-Estadisticas-de-Comercio-Exterior-Importaciones-y-Exportaciones.aspx>
- [2] Departamento Administrativo Nacional de Estadística - DANE. (2026). *Comercio exterior: Metodología y validación de estadísticas de exportaciones*. Recuperado de <https://www.dane.gov.co>
- [3] Montgomery, D. C., & Runger, G. C. (2018). *Applied statistics and probability for engineers* (7th ed.). Wiley.
- [4] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3/4), 591–611. <https://doi.org/10.2307/2333709>

A. Apéndice: Código fuente

```
1 # =====
2 # Proyecto Integrador - Analítica Descriptiva II
3 # Avance 1: EDA - Exportaciones Colombia (DIAN, Junio 2026)
4 # Fuente: https://www.dian.gov.co/dian/cifras/Paginas/
   EstadisticasComEx.aspx
5 # Fecha de descarga del archivo: 12/08/2026
6 # Equipo: Angie Montero, Michael Baquero
7 # =====
8
9 # Importe de librerías
10 import os
11 import pandas as pd
12 import dataframe_image as dfi
13 import matplotlib.pyplot as plt
14 import seaborn as sns
15 from scipy.stats import shapiro, probplot, skew
16
17
18 def exportar_imagen(path):
19     """
20     Elimina la imagen existente en 'path' (si existe) antes de
21     generar
22     la nueva. Evita que queden versiones desactualizadas en Doc/
23     anexos/
24     cuando se vuelve a correr el script tras un cambio.
25     """
26     if os.path.exists(path):
27         os.remove(path)
28
29 # Lectura del documento
30 df = pd.read_excel("Data/06_Exportaciones_2026_Junio.xlsx")
31
32 # Visualización inicial del dataframe
33 print('Visualización de primeras filas:\n', df.head(5))
34 print('\nVisualización de las dimensiones: ', df.shape)
35 print(df.info())
36
37 # Exportación: resumen del dataset ORIGINAL
38 resumen_original = pd.DataFrame({
39     "Dataset": ["Original"],
40     "Filas": [df.shape[0]],
41     "Columnas": [df.shape[1]],
42     "Columnas numéricas": [df.select_dtypes(include="number").shape
43                             [1]],
```

```

42     "Columnas categóricas/texto": [df.select_dtypes(include="object")
43         .shape[1]]
44 })
45 exportar_imagen("Doc/anexos/tabla_resumen_original.png")
46 dfi.export(resumen_original.style.hide(axis='index'),
47     "Doc/anexos/tabla_resumen_original.png")
48
49 # Exploración preliminar de variables categóricas candidatas
50 categoricas_candidatas = [
51     "MODO_TRANSPORTE",
52     "MODALIDAD_EXPORTACION",
53     "PAIS_DESTINO_FINAL",
54     "REGION_DE_ORIGEN",
55     "TIPO_DE_EMBARQUE"
56 ]
57 for col in categoricas_candidatas:
58     print(col, "->", df[col].nunique(), "categorías únicas")
59
60 # Exportación: número de categorías únicas por variable categórica
61 # candidata
62 resumen_categoricas = pd.DataFrame({
63     "Variable": categoricas_candidatas,
64     "Categorías únicas": [df[col].nunique() for col in
65         categoricas_candidatas]
66 })
67 exportar_imagen("Doc/anexos/tabla_categoricas.png")
68 dfi.export(resumen_categoricas.style.hide(axis='index'),
69     "Doc/anexos/tabla_categoricas.png")
70
71 # Filtro de columnas relevantes (se excluye PAIS_DESTINO_FINAL)
72 columnas_relevantes = [
73     "VALOR_FOB_USD",
74     "PESO_NETO_KGS",
75     "PESO_BRUTO_KGS",
76     "VLR_SERIE_AGREGADO_NAL_USD",
77     "VALOR_SERIE_FLETES_USD",
78     "VALOR_SERIE_SEGUROS_USD",
79     "CANTIDAD_UNIDADES_FISICAS",
80     "MODO_TRANSPORTE",
81     "MODALIDAD_EXPORTACION",
82     "REGION_DE_ORIGEN",
83     "TIPO_DE_EMBARQUE"
84 ]
85 df_filtrado = df[columnas_relevantes]
86
87 # Renombres para nombres cortos y legibles
88 renombres = {
89     "VALOR_FOB_USD": "Valor FOB (USD)",

```

```

87     "PESO_NETO_KGS": "Peso Neto (Kg)",
88     "PESO_BRUTO_KGS": "Peso Bruto (Kg)",
89     "VLR_SERIE_AGREGADO_NAL_USD": "Vlr. Serie Nal (USD)",
90     "VALOR_SERIE_FLETES_USD": "Fletes (USD)",
91     "VALOR_SERIE_SEGUROS_USD": "Seguros (USD)",
92     "CANTIDAD_UNIDADES_FISICAS": "Cant. Unidades",
93     "MODO_TRANSPORTE": "Modo Transporte",
94     "MODALIDAD_EXPORTACION": "Modalidad",
95     "REGION_DE_ORIGEN": "Región Origen",
96     "TIPO_DE_EMBARQUE": "Tipo Embarque"
97 }
98 df_filtrado = df_filtrado.rename(columns=renombres)
99
100 # Diccionario con descripciones
101 descripciones = {
102     "VALOR_FOB_USD": "Valor de la mercancía en dólares (FOB: Free On
103         Board, sin fletes ni seguros).",
104     "PESO_NETO_KGS": "Peso neto de la mercancía en kilogramos (sin
105         incluir embalaje).",
106     "PESO_BRUTO_KGS": "Peso bruto de la mercancía en kilogramos (
107         incluyendo embalaje).",
108     "VLR_SERIE_AGREGADO_NAL_USD": "Valor total de la serie agregada
109         nacional en dólares.",
110     "VALOR_SERIE_FLETES_USD": "Valor de los fletes internacionales en
111         dólares.",
112     "VALOR_SERIE_SEGUROS_USD": "Valor de los seguros internacionales
113         en dólares.",
114     "CANTIDAD_UNIDADES_FISICAS": "Cantidad de unidades físicas de la
115         mercancía.",
116     "MODO_TRANSPORTE": "Modo de transporte utilizado (marítimo, aéreo
117         , terrestre, etc.).",
118     "MODALIDAD_EXPORTACION": "Modalidad de exportación (definitiva,
119         temporal, etc.).",
120     "REGION_DE_ORIGEN": "Región de origen de la mercancía en Colombia
121         .",
122     "TIPO_DE_EMBARQUE": "Tipo de embarque (único, consolidado, etc.).
123         "
124 }
125
126 # Exportación: tabla de variables seleccionadas
127 tabla_variables = pd.DataFrame({
128     "Variable": [renombres[col] for col in columnas_relevantes],
129     "Tipo": [str(df_filtrado[col].dtype) for col in df_filtrado.
130         columns],
131     "Descripción": [descripciones[col] for col in columnas_relevantes
132         ]
133 })
134 exportar_imagen("Doc/anexos/tabla_variables_seleccionadas.png")

```

```

122 dfi.export(tabla_variables.style.hide(axis='index'),
123            "Doc/anexos/tabla_variables_seleccionadas.png")
124
125 # Validación de valores nulos
126 print('\nVisualización de valores nulos:\n', df_filtrado.isnull().sum
      ())
127
128 # Muestreo inicial (sobre el dataset filtrado)
129 df_muestra = df_filtrado.sample(n=1500, random_state=42).reset_index(
      drop=True)
130 print(f"\nMuestra obtenida: {df_muestra.shape[0]} filas")
131
132 # Q-Q plot de la muestra con outliers.
133 # Se genera como evidencia visual del problema de no normalidad,
      antes
134 # de aplicar el tratamiento de outliers.
135 plt.figure(figsize=(8, 6))
136 probplot(df_muestra['Valor FOB (USD)'].dropna(), dist="norm", plot=
      plt)
137 plt.title('Q-Q plot - Muestra (con outliers)', fontsize=14)
138 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
139 plt.ylabel('Cuantiles muestrales', fontsize=12)
140 plt.grid(alpha=0.4)
141 plt.tight_layout()
142 exportar_imagen('Doc/anexos/qplot_muestra_con_outliers.png')
143 plt.savefig('Doc/anexos/qplot_muestra_con_outliers.png', dpi=300)
144 plt.close()
145
146 # Detección de outliers sobre la muestra (método IQR)
147 Q1 = df_muestra['Valor FOB (USD)'].quantile(0.25)
148 Q3 = df_muestra['Valor FOB (USD)'].quantile(0.75)
149 IQR = Q3 - Q1
150 lower_bound = Q1 - 1.5 * IQR
151 upper_bound = Q3 + 1.5 * IQR
152
153 outliers_mask = (df_muestra['Valor FOB (USD)'] < lower_bound) | (
      df_muestra['Valor FOB (USD)'] > upper_bound)
154 outliers = df_muestra[outliers_mask]
155
156 num_outliers = len(outliers)
157 total_rows = len(df_muestra)
158 pct_outliers = 100 * num_outliers / total_rows
159
160 # Exportación: tabla resumen de la detección de outliers
161 tabla_outliers = pd.DataFrame({
162     "Métrica": [
163         "Total de filas en la muestra",
164         "Outliers detectados",

```

```

165         "Porcentaje de outliers",
166         "Límite inferior (Q1 - 1.5*IQR)",
167         "Límite superior (Q3 + 1.5*IQR)",
168         "Valor mínimo en la muestra",
169         "Valor máximo en la muestra",
170         "Q1",
171         "Q3",
172         "IQR"
173     ],
174     "Valor": [
175         f"{total_rows}",
176         f"{num_outliers}",
177         f"{pct_outliers:.2f}%",
178         f"{lower_bound:.2f}",
179         f"{upper_bound:.2f}",
180         f"{df_muestra['Valor FOB (USD)'].min():.2f}",
181         f"{df_muestra['Valor FOB (USD)'].max():.2f}",
182         f"{Q1:.2f}",
183         f"{Q3:.2f}",
184         f"{IQR:.2f}"
185     ]
186 })
187 exportar_imagen("Doc/anexos/tabla_outliers_muestra.png")
188 dfi.export(tabla_outliers.style.hide(axis='index'),
189            "Doc/anexos/tabla_outliers_muestra.png")
190
191 print("\n--- Resumen de outliers (sobre la muestra) ---")
192 print(tabla_outliers.to_string(index=False))
193
194 # Exclusión de outliers para obtener la muestra de trabajo definitiva
195 df_muestra_clean = df_muestra[~outliers_mask].copy()
196 print(f"\nFilas después de excluir outliers: {len(df_muestra_clean)}"
197       )
198
199 # Sección a cargo de Angie: estadística descriptiva y visualizaciones
200 # sobre las variables numéricas de df_muestra_clean (muestra sin
201     outliers).
202
203 # (Shapiro-Wilk + gráfico Q-Q) para Valor FOB (USD), sobre la muestra
204 # ya depurada de outliers (df_muestra_clean), que es la que se usa en
205 # el resto del proyecto.
206 variable = df_muestra_clean['Valor FOB (USD)'].dropna()
207 print(f"\nRegistros válidos para la prueba: {len(variable)}")
208
209 estadistico_w, p_valor = shapiro(variable)
210

```

```

211 # Se reporta el valor p redondeado en formato decimal, no en notación
212 # científica. Cuando el valor es extremadamente pequeño (menor a
    0.001),
213 # se reporta como "< 0.001" en vez de un número con muchos ceros,
214 # siguiendo la convención estándar de reporte de pruebas de hipótesis
    .
215 if p_valor < 0.001:
216     p_valor_str = "< 0.001"
217 else:
218     p_valor_str = f"{p_valor:.3f}"
219
220 print(f"\nEstadístico W: {estadistico_w:.4f}")
221 print(f"Valor p: {p_valor_str}")
222
223 alfa = 0.05
224 print(f"\nNivel de significancia (alfa): {alfa}")
225 if p_valor > alfa:
226     conclusion = "NO se rechaza H0. Los datos podrían provenir de una
        distribución normal (no hay evidencia suficiente en contra)."
227 else:
228     conclusion = "SE RECHAZA H0. Existe evidencia estadística
        significativa de que los datos NO siguen una distribución
        normal."
229 print(f"Conclusión: {conclusion}")
230
231 # Gráfico Q-Q de la muestra limpia, como evidencia visual que
232 # complementa el resultado numérico de Shapiro-Wilk.
233 plt.figure(figsize=(8, 6))
234 probplot(variable, dist="norm", plot=plt)
235 plt.title('Q-Q plot - Muestra sin outliers', fontsize=14)
236 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
237 plt.ylabel('Cuantiles muestrales', fontsize=12)
238 plt.grid(alpha=0.4)
239 plt.tight_layout()
240 exportar_imagen('Doc/anexos/qqplot_muestra_sin_outliers.png')
241 plt.savefig('Doc/anexos/qqplot_muestra_sin_outliers.png', dpi=300)
242 plt.close()
243
244 # Exportación: comparación de dimensiones muestra inicial vs. sin
    outliers.
245 resumen_muestra = pd.DataFrame({
246     "Dataset": ["Muestra inicial (seed 42)", "Muestra sin outliers"],
247     "Filas": [df_muestra.shape[0], df_muestra_clean.shape[0]],
248     "Columnas": [df_muestra.shape[1], df_muestra_clean.shape[1]]
249 })
250 exportar_imagen("Doc/anexos/tabla_dimensiones_muestra.png")
251 dfi.export(resumen_muestra.style.hide(axis='index'),
252     "Doc/anexos/tabla_dimensiones_muestra.png")

```

```
253
254 # Exportación: primeras filas de la muestra limpia, redondeada a 2
255 # decimales. Se oculta el índice para mantener el mismo estilo visual
256 # que las demás tablas exportadas.
257 muestra_head = df_muestra_clean.head(5).round(2)
258 exportar_imagen("Doc/anexos/tabla_muestra_head.png")
259 dfi.export(muestra_head.style.hide(axis='index'),
260            "Doc/anexos/tabla_muestra_head.png")
```