



Análisis Exploratorio de Exportaciones Colombianas

(Junio 2026)

Angie Paola Montero Tique
Michael Yesid Baquero Gomez

Analítica Descriptiva II
Unicafam
Agosto 2026

1. Introducción

El comercio exterior es uno de los pilares de la actividad económica colombiana, y su seguimiento estadístico permite comprender el comportamiento de los sectores productivos que participan en él [1]. La Dirección de Impuestos y Aduanas Nacionales (DIAN), en conjunto con el Departamento Administrativo Nacional de Estadística (DANE), produce y certifica mensualmente las estadísticas oficiales de exportaciones del país, las cuales constituyen una de las fuentes más completas y confiables para el análisis cuantitativo de esta actividad [2]. Dentro de estas estadísticas, variables como el valor FOB, el peso de la mercancía y los costos de flete permiten caracterizar no solo cuánto exporta el país, sino también bajo qué condiciones logísticas y económicas se realizan dichas operaciones.

A pesar de la disponibilidad de esta información, no es evidente a simple vista cómo se relacionan el peso de las mercancías exportadas con su valor comercial y con los costos asociados al transporte internacional. Comprender esta relación es relevante tanto para empresas exportadoras, que buscan optimizar sus costos logísticos, como para quienes diseñan política de comercio exterior, interesados en identificar patrones de eficiencia según el tipo de mercancía o el modo de transporte utilizado. De este panorama surge la pregunta de investigación que orienta el presente proyecto: **¿cómo se relaciona el peso de las mercancías con el valor FOB y los costos de flete en las exportaciones colombianas de junio de 2026?**

Para responder a esta pregunta, se plantean los siguientes objetivos:

Objetivo general: Analizar la relación entre el peso de las mercancías exportadas y sus costos asociados (valor FOB y fletes) en las exportaciones colombianas de junio de 2026, mediante técnicas de estadística inferencial.

Objetivos específicos:

1. Caracterizar estadísticamente las variables de valor, peso y costos de las exportaciones seleccionadas.
2. Evaluar el cumplimiento del supuesto de normalidad de la variable Valor FOB (USD), antes y después del tratamiento de valores atípicos.
3. Determinar, mediante un modelo de regresión lineal simple, la relación entre el peso neto de la mercancía y su valor FOB.
4. Comparar los costos de flete asociados a las exportaciones según el modo de transporte utilizado.

Este análisis resulta de interés para empresas exportadoras que buscan dimensionar sus costos logísticos en función del peso de sus productos, así como para actores del sector público interesados en identificar patrones de eficiencia en el comercio exterior colombiano. El estudio se limita a las exportaciones registradas por la DIAN durante el mes de junio de 2026, y se desarrolla sobre una muestra aleatoria de 1.500 registros, de la cual se excluyeron 394 valores atípicos (26.27 %) mediante el método del rango intercuartílico (IQR), aplicado sobre las variables Valor FOB (USD), Peso Neto (Kg) y Cant. Unidades, obteniendo una muestra final de 1.106 registros para el análisis.

2. Descripción del dataset

Los datos utilizados en este estudio provienen de la base de **Estadísticas de Comercio Exterior – Exportaciones**, publicada por la Dirección de Impuestos y Aduanas Nacionales (DIAN), validada y certificada por el Departamento Administrativo Nacional de Estadística (DANE). Corresponde al mes de junio de 2026 y fue descargada el 12 de agosto de 2026 desde la página oficial de estadísticas de comercio exterior de la DIAN.

El archivo original contiene un total de 103.179 registros y 72 variables. Dentro de este conjunto de datos, se identificaron 44 columnas de tipo numérico y 28 columnas de tipo categórico o texto, tal como se resume en la Tabla 1.

Dataset	Filas	Columnas	Columnas numéricas	Columnas categóricas/texto
Original	103179	72	44	28

Figura 1: Resumen del dataset original de exportaciones (junio 2026).

Exploración de variables categóricas

Para determinar qué variables categóricas eran adecuadas para las pruebas de hipótesis del proyecto, se realizó una exploración inicial sobre las variables candidatas: `MODO_TRANSPORTE`, `MODALIDAD_EXPORTACION`, `PAIS_DESTINO_FINAL`, `REGION_DE_ORIGEN` y `TIPO_DE_EMBARQUE`. El objetivo fue evaluar el número de categorías únicas presentes en cada una, ya que un número excesivo de categorías dificulta el análisis estadístico (Tabla 2).

Variable	Categorías únicas
<code>MODO_TRANSPORTE</code>	4
<code>MODALIDAD_EXPORTACION</code>	10
<code>PAIS_DESTINO_FINAL</code>	173
<code>REGION_DE_ORIGEN</code>	31
<code>TIPO_DE_EMBARQUE</code>	3

Figura 2: Número de categorías únicas por variable categórica candidata.

Con base en este análisis, se identificó que la variable `PAIS_DESTINO_FINAL` presenta un total de 173 categorías únicas. Esta alta cardinalidad la hace estadísticamente inviable para pruebas de hipótesis del tipo chi-cuadrado, ya que generaría una matriz de contingencia demasiado dispersa y sin poder explicativo. Por lo tanto, se decidió excluirla del análisis.

Selección de variables finales

Tras la exclusión de `PAIS_DESTINO_FINAL`, se seleccionaron 11 variables relevantes que orientan el desarrollo de la pregunta de investigación y el modelo de regresión final. Esta

selección incluye tanto variables cuantitativas (como valores monetarios y pesos) como variables categóricas de baja cardinalidad. La descripción técnica de cada variable seleccionada se presenta en la Tabla 3.

Variable	Tipo	Descripción
Valor FOB (USD)	float64	Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).
Peso Neto (Kg)	float64	Peso neto de la mercancía en kilogramos (sin incluir embalaje).
Peso Bruto (Kg)	float64	Peso bruto de la mercancía en kilogramos (incluyendo embalaje).
Vlr. Serie Nal (USD)	float64	Valor total de la serie agregada nacional en dólares.
Fletes (USD)	float64	Valor de los fletes internacionales en dólares.
Seguros (USD)	float64	Valor de los seguros internacionales en dólares.
Cant. Unidades	float64	Cantidad de unidades físicas de la mercancía.
Modo Transporte	object	Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).
Modalidad	object	Modalidad de exportación (definitiva, temporal, etc.).
Región Origen	object	Región de origen de la mercancía en Colombia.
Tipo Embarque	object	Tipo de embarque (único, consolidado, etc.).

Figura 3: Variables seleccionadas del dataset de exportaciones.

Muestreo y tratamiento de outliers

Dado el volumen del dataset filtrado y con el fin de optimizar los recursos computacionales, se optó por trabajar con una muestra aleatoria simple de 1.500 registros. Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados. Esta reducción evita sobrecargar el modelo de regresión lineal y reduce significativamente los tiempos de ejecución.

Una vez extraída la muestra, se aplicó un procedimiento sistemático para detectar y excluir valores atípicos (outliers) sobre tres variables cuantitativas: *Valor FOB (USD)*, *Peso Neto (Kg)* y *Cant. Unidades*. Se utilizó el método del rango intercuartílico (IQR), considerando como outlier todo valor por debajo de $Q_1 - 1,5 \times IQR$ o por encima de $Q_3 + 1,5 \times IQR$ en al menos una de las tres variables. La Tabla 4 resume los estadísticos clave de este procedimiento, detallados por variable, así como el total combinado.

Variable	Outliers detectados	Porcentaje	Límite inferior	Límite superior	Q1	Q3	IQR
Valor FOB (USD)	223	14.87%	-16258.31	28163.49	399.86	11505.31	11105.45
Peso Neto (Kg)	267	17.80%	-2968.16	5018.47	26.82	2023.48	1996.66
Cant. Unidades	269	17.93%	-6177.74	10413.56	44.00	4191.83	4147.83
TOTAL (unión de las 3 variables)	394	26.27%	-	-	-	-	-

Figura 4: Estadísticos de detección de outliers sobre la muestra (n=1500), por variable.

En total se detectaron **394 registros atípicos** (26.27 % de la muestra), considerando la unión de valores extremos en las tres variables analizadas: 223 en *Valor FOB (USD)* (14.87 %), 267 en *Peso Neto (Kg)* (17.80 %) y 269 en *Cant. Unidades* (17.93 %). Estos registros se excluyeron para obtener una muestra depurada de **1.106** registros, sobre la cual se realizó el análisis exploratorio y las pruebas de normalidad.

La Tabla 5 compara las dimensiones de la muestra inicial (con outliers) y la muestra final sin outliers.

Dataset	Filas	Columnas
Muestra inicial (seed 42)	1500	11
Muestra sin outliers	1106	11

Figura 5: Comparación de dimensiones: muestra inicial vs. muestra sin outliers.

A modo de ejemplo tangible, la Tabla 6 presenta las primeras cinco filas de la muestra de trabajo ya depurada. Se puede observar cómo se estructuran los datos de las variables cuantitativas y categóricas seleccionadas para el estudio.

Valor FOB (USD)	Peso Neto (Kg)	Peso Bruto (Kg)	Vir. Serie Nal (USD)	Fletes (USD)	Seguros (USD)	Cant. Unidades	Modo Transporte	Modalidad	Región Origen	Tipo Embarque
1932.880000	722.540000	743.930000	0.000000	0.000000	0.000000	722.540000	Marítimo	Exportación definitiva de mercancías de fabricación o producción nacional	ANTIOQUIA	Unico
2797.250000	558.000000	573.930000	2412.380000	215.880000	0.000000	9.000000	Terrestre (carretero)	Las demás exportaciones definitivas no incluidas como exportaciones definitivas	CALDAS	Unico
530.910000	23.260000	28.750000	0.000000	0.000000	0.000000	23.260000	Terrestre (carretero)	Exportación definitiva de mercancías de fabricación o producción nacional	ANTIOQUIA	Unico
280.000000	63.550000	64.650000	0.000000	0.000000	0.000000	63.550000	Terrestre (carretero)	Exportación definitiva de mercancías de fabricación o producción nacional	NORTE DE SANTANDER	Unico
715.590000	224.710000	229.300000	0.000000	0.000000	0.000000	224.710000	Aéreo	Exportación definitiva de mercancías de fabricación o producción nacional	CUNDINAMARCA	Unico

Figura 6: Primeras 5 filas de la muestra final (sin outliers).

3. Análisis exploratorio

A partir de la muestra depurada descrita en la sección anterior, se llevó a cabo un análisis exploratorio que incluye la estadística descriptiva de las variables cuantitativas, visualizaciones comparativas antes y después del tratamiento de outliers, y la verificación formal del supuesto de normalidad, como base para las etapas posteriores de prueba de hipótesis y regresión lineal.

3.1. Estadística descriptiva

Para dimensionar el efecto del tratamiento de outliers sobre las variables cuantitativas, se calcularon los estadísticos descriptivos (media, mediana, desviación estándar, mínimo, máximo y asimetría) tanto para la muestra con outliers (1.500 registros) como para la muestra depurada (1.106 registros). La Tabla 7 presenta los resultados sobre la muestra con outliers, mientras que la Tabla 8 presenta los mismos estadísticos sobre la muestra sin outliers.

	count	mean	std	min	25%	50%	75%	max	Asimetría
Valor FOB (USD)	1500.0	52720.09	916701.21	0.06	399.86	2023.00	11505.31	34800615.03	36.49
Peso Neto (Kg)	1500.0	60707.41	1905363.94	0.01	26.82	209.50	2023.48	73538808.00	38.29
Peso Bruto (Kg)	1500.0	61142.05	1905431.48	0.01	30.28	238.88	2220.53	73538808.00	38.29
Vir. Serie Nal (USD)	1500.0	8157.61	69687.32	0.00	0.00	0.00	328.46	1696214.53	17.76
Fletes (USD)	1500.0	264.57	1426.91	0.00	0.00	0.00	10.97	35499.84	15.29
Seguros (USD)	1500.0	17.18	376.23	0.00	0.00	0.00	0.00	14249.42	36.31
Cant. Unidades	1500.0	23548.58	211590.49	0.01	44.00	326.92	4191.83	6046090.00	20.75

Figura 7: Estadística descriptiva de las variables numéricas – muestra con outliers.

	count	mean	std	min	25%	50%	75%	max	Asimetría
Valor FOB (USD)	1106.0	2860.39	4675.58	0.06	235.24	959.00	2951.61	27944.90	2.73
Peso Neto (Kg)	1106.0	428.85	842.60	0.01	14.84	83.00	378.75	4922.68	2.95
Peso Bruto (Kg)	1106.0	475.57	917.26	0.01	16.59	91.31	437.20	6211.00	2.93
Vir. Serie Nal (USD)	1106.0	738.97	2347.68	0.00	0.00	0.00	78.41	20682.63	4.78
Fletes (USD)	1106.0	68.08	300.16	0.00	0.00	0.00	4.24	4178.69	7.99
Seguros (USD)	1106.0	1.37	9.65	0.00	0.00	0.00	0.00	147.94	10.60
Cant. Unidades	1106.0	802.81	1599.73	0.01	25.00	140.50	718.50	10000.00	3.19

Figura 8: Estadística descriptiva de las variables numéricas – muestra sin outliers.

Al ampliar el criterio IQR a tres variables (Valor FOB, Peso Neto y Cant. Unidades), la mejora en la forma de la distribución es aún más marcada que con el tratamiento aplicado

únicamente a Valor FOB. La asimetría de *Valor FOB (USD)* se reduce de **36.49** a **2.73**, y la de *Peso Neto (Kg)* de **38.29** a **2.95**. La desviación estándar de *Valor FOB (USD)* cae de 916,701,21 a 4,675,58, quedando en un orden de magnitud comparable al de su media (2,860,39). Este resultado confirma que el tratamiento conjunto de outliers en las tres variables produce una muestra considerablemente más representativa del comportamiento típico de las exportaciones, sin la distorsión que generaban los valores extremos de peso y cantidad que no se habían tratado en la primera versión del análisis.

3.2. Visualizaciones

Las Figuras 9–12 presentan los histogramas de *Valor FOB (USD)* y *Peso Neto (Kg)*, antes y después de la exclusión de outliers, permitiendo observar el cambio en la forma de la distribución.




Figura 9: Distribución de Valor FOB (USD) – muestra con outliers.




Figura 10: Distribución de Valor FOB (USD) – muestra sin outliers.




Figura 11: Distribución de Peso Neto (Kg) – muestra con outliers.




Figura 12: Distribución de Peso Neto (Kg) – muestra sin outliers.

Los histogramas con outliers (Figuras 9 y 11) muestran prácticamente la totalidad de las observaciones concentradas en una única barra cercana a cero, con el resto del eje horizontal vacío – consecuencia de que unos pocos valores extremos estiran la escala del gráfico hasta comprimir toda la variabilidad real en un rango casi imperceptible. Al excluir los outliers en las tres variables (Figuras 10 y 12), ambas distribuciones recuperan una forma interpretable: una alta concentración de exportaciones de bajo valor y peso, seguida de una cola derecha decreciente que refleja un número menor de exportaciones de mayor magnitud. Esta forma, característica de una distribución de tipo log-normal, respalda la recomendación de aplicar una transformación logarítmica antes de construir el modelo de regresión lineal.

3.3. Verificación de normalidad

Como evidencia inicial del problema de normalidad, la Figura 13 muestra el gráfico Q-Q de la muestra de 1.500 registros antes de excluir valores atípicos, donde se observa una clara desviación de los puntos respecto a la línea de referencia en los cuantiles superiores, evidenciando la presencia de colas pesadas y valores extremos.




Figura 13: Gráfico Q-Q para la muestra inicial (con outliers).

Tras la exclusión de los 394 outliers detectados mediante el método IQR sobre las tres variables analizadas (ver sección de Muestreo y tratamiento de outliers), se aplicó la prueba de Shapiro-Wilk sobre la muestra depurada de 1.106 registros para evaluar formalmente el supuesto de normalidad de la variable *Valor FOB (USD)*.

Los resultados obtenidos fueron los siguientes:

- Estadístico de prueba (W): **0.6277**
- Valor p : **<0.001**

Dado que el valor p es inferior al nivel de significancia $\alpha = 0,05$, se **rechaza la hipótesis nula**. Existe evidencia estadística de que la variable *Valor FOB (USD)*, incluso tras la exclusión conjunta de outliers en Valor FOB, Peso Neto y Cant. Unidades, **no sigue una distribución normal**. El gráfico Q-Q de la Figura 14 respalda este resultado: si bien el punto extremo aislado que se observaba en la muestra original desaparece, los cuantiles muestrales siguen desviándose de la línea de referencia de forma sistemática – por debajo de la diagonal en los cuantiles inferiores y por encima en los superiores – patrón típico de una distribución con cola derecha más pesada que la normal, coherente con la asimetría de **2.73** reportada en la sección de estadística descriptiva.




Figura 14: Gráfico Q-Q para la muestra sin outliers.

En consecuencia, para el modelo de regresión lineal que se desarrollará en etapas posteriores, se recomienda aplicar una transformación logarítmica a la variable *Valor FOB (USD)* con el fin de aproximar su comportamiento a una distribución normal y cumplir con los supuestos del modelo.

Referencias

Referencias

- [1] Dirección de Impuestos y Aduanas Nacionales - DIAN. (2026). *Estadísticas de comercio exterior - Exportaciones (junio 2026)*. Recuperado de <https://www.dian.gov.co/dian/cifras/Paginas/Bases-Estadisticas-de-Comercio-Exterior-Importaciones-y-Exportaciones.aspx>
- [2] Departamento Administrativo Nacional de Estadística - DANE. (2026). *Comercio exterior: Metodología y validación de estadísticas de exportaciones*. Recuperado de <https://www.dane.gov.co>
- [3] Montgomery, D. C., & Runger, G. C. (2018). *Applied statistics and probability for engineers* (7th ed.). Wiley.
- [4] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3/4), 591–611. <https://doi.org/10.2307/2333709>

A. Apéndice: Código fuente

```
1 # =====
2 # Proyecto Integrador - Analítica Descriptiva II
3 # Avance 1: EDA - Exportaciones Colombia (DIAN, Junio 2026)
4 # Fuente: https://www.dian.gov.co/dian/cifras/Paginas/
   EstadisticasComEx.aspx
5 # Fecha de descarga del archivo: 12/08/2026
6 # Equipo: Angie Montero, Michael Baquero
7 # =====
8
9 # Importe de librerías
10 import os
11 import pandas as pd
12 import dataframe_image as dfi
13 import matplotlib.pyplot as plt
14 import seaborn as sns
15 from scipy.stats import shapiro, probplot, skew
16
17
18 def exportar_imagen(path):
19     """
20     Elimina la imagen existente en 'path' (si existe) antes de
21     generar
22     la nueva. Evita que queden versiones desactualizadas en Doc/
23     anexos/
24     cuando se vuelve a correr el script tras un cambio.
25     """
26     if os.path.exists(path):
27         os.remove(path)
28
29 # -----
30 # Descripción del dataset
31 # -----
32
33 # Lectura del documento
34 df = pd.read_excel("Data/06_Exportaciones_2026_Junio.xlsx")
35
36 # Visualización inicial del dataframe
37 print('Visualización de primeras filas:\n', df.head(5))
38 print('\nVisualización de las dimensiones: ', df.shape)
39 print(df.info())
40
41 # Exportación: resumen del dataset ORIGINAL
42 resumen_original = pd.DataFrame({
43     "Dataset": ["Original"],
```

```

43     "Filas": [df.shape[0]],
44     "Columnas": [df.shape[1]],
45     "Columnas numéricas": [df.select_dtypes(include="number").shape
46         [1]],
47     "Columnas categóricas/texto": [df.select_dtypes(include="object")
48         .shape[1]]
49 })
50 exportar_imagen("Doc/anexos/tabla_resumen_original.png")
51 dfi.export(resumen_original.style.hide(axis='index'),
52     "Doc/anexos/tabla_resumen_original.png")
53
54 # Exploración preliminar de variables categóricas candidatas
55 categoricas_candidatas = [
56     "MODO_TRANSPORTE",
57     "MODALIDAD_EXPORTACION",
58     "PAIS_DESTINO_FINAL",
59     "REGION_DE_ORIGEN",
60     "TIPO_DE_EMBARQUE"
61 ]
62
63 for col in categoricas_candidatas:
64     print(col, "->", df[col].nunique(), "categorías únicas")
65
66 # Exportación: número de categorías únicas por variable categórica
67 # candidata
68 resumen_categoricas = pd.DataFrame({
69     "Variable": categoricas_candidatas,
70     "Categorías únicas": [df[col].nunique() for col in
71         categoricas_candidatas]
72 })
73 exportar_imagen("Doc/anexos/tabla_categoricas.png")
74 dfi.export(resumen_categoricas.style.hide(axis='index'),
75     "Doc/anexos/tabla_categoricas.png")
76
77 # Filtro de columnas relevantes (se excluye PAIS_DESTINO_FINAL)
78 columnas_relevantes = [
79     "VALOR_FOB_USD",
80     "PESO_NETO_KGS",
81     "PESO_BRUTO_KGS",
82     "VLR_SERIE_AGREGADO_NAL_USD",
83     "VALOR_SERIE_FLETES_USD",
84     "VALOR_SERIE_SEGUROS_USD",
85     "CANTIDAD_UNIDADES_FISICAS",
86     "MODO_TRANSPORTE",
87     "MODALIDAD_EXPORTACION",
88     "REGION_DE_ORIGEN",
89     "TIPO_DE_EMBARQUE"
90 ]
91 df_filtrado = df[columnas_relevantes]

```

```

87
88 # Renombres para nombres cortos y legibles
89 renombres = {
90     "VALOR_FOB_USD": "Valor FOB (USD)",
91     "PESO_NETO_KGS": "Peso Neto (Kg)",
92     "PESO_BRUTO_KGS": "Peso Bruto (Kg)",
93     "VLR_SERIE_AGREGADO_NAL_USD": "Vlr. Serie Nal (USD)",
94     "VALOR_SERIE_FLETES_USD": "Fletes (USD)",
95     "VALOR_SERIE_SEGUROS_USD": "Seguros (USD)",
96     "CANTIDAD_UNIDADES_FISICAS": "Cant. Unidades",
97     "MODO_TRANSPORTE": "Modo Transporte",
98     "MODALIDAD_EXPORTACION": "Modalidad",
99     "REGION_DE_ORIGEN": "Región Origen",
100    "TIPO_DE_EMBARQUE": "Tipo Embarque"
101 }
102 df_filtrado = df_filtrado.rename(columns=renombres)
103
104 # Diccionario con descripciones
105 descripciones = {
106     "VALOR_FOB_USD": "Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).",
107     "PESO_NETO_KGS": "Peso neto de la mercancía en kilogramos (sin incluir embalaje).",
108     "PESO_BRUTO_KGS": "Peso bruto de la mercancía en kilogramos (incluyendo embalaje).",
109     "VLR_SERIE_AGREGADO_NAL_USD": "Valor total de la serie agregada nacional en dólares.",
110     "VALOR_SERIE_FLETES_USD": "Valor de los fletes internacionales en dólares.",
111     "VALOR_SERIE_SEGUROS_USD": "Valor de los seguros internacionales en dólares.",
112     "CANTIDAD_UNIDADES_FISICAS": "Cantidad de unidades físicas de la mercancía.",
113     "MODO_TRANSPORTE": "Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).",
114     "MODALIDAD_EXPORTACION": "Modalidad de exportación (definitiva, temporal, etc.).",
115     "REGION_DE_ORIGEN": "Región de origen de la mercancía en Colombia.",
116     "TIPO_DE_EMBARQUE": "Tipo de embarque (único, consolidado, etc.)."
117 }
118
119 # Exportación: tabla de variables seleccionadas
120 tabla_variables = pd.DataFrame({
121     "Variable": [renombres[col] for col in columnas_relevantes],
122     "Tipo": [str(df_filtrado[col].dtype) for col in df_filtrado.columns],

```

```

123     "Descripción": [descripciones[col] for col in columnas_relevantes
124 ]
125 })
126 exportar_imagen("Doc/anexos/tabla_variables_seleccionadas.png")
127 dfi.export(tabla_variables.style.hide(axis='index'),
128            "Doc/anexos/tabla_variables_seleccionadas.png")
129
130 # Validación de valores nulos
131 print('\nVisualización de valores nulos:\n', df_filtrado.isnull().sum
132 ())
133
134 # Muestreo inicial (sobre el dataset filtrado)
135 df_muestra = df_filtrado.sample(n=1500, random_state=42).reset_index(
136     drop=True)
137 print(f"\nMuestra obtenida: {df_muestra.shape[0]} filas")
138
139 # Q-Q plot de la muestra con outliers.
140 # Se genera como evidencia visual del problema de no normalidad,
141 # antes
142 # de aplicar el tratamiento de outliers.
143 plt.figure(figsize=(8, 6))
144 probplot(df_muestra['Valor FOB (USD)'].dropna(), dist="norm", plot=
145 plt)
146 plt.title('Q-Q plot - Muestra (con outliers)', fontsize=14)
147 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
148 plt.ylabel('Cuantiles muestrales', fontsize=12)
149 plt.grid(alpha=0.4)
150 plt.tight_layout()
151 exportar_imagen('Doc/anexos/qqplot_muestra_con_outliers.png')
152 plt.savefig('Doc/anexos/qqplot_muestra_con_outliers.png', dpi=300)
153 plt.close()
154
155 # Detección de outliers sobre la muestra (método IQR), aplicado a las
156 # tres variables cuantitativas con mayor cardinalidad de valores
157 # extremos: Valor FOB (USD), Peso Neto (Kg) y Cant. Unidades. Una
158 # fila
159 # se considera atípica si lo es en AL MENOS UNA de estas tres
160 # variables
161 # (unión de máscaras), de modo que la muestra depurada quede libre de
162 # outliers en las tres a la vez.
163 variables_outlier = ["Valor FOB (USD)", "Peso Neto (Kg)", "Cant.
164     Unidades"]
165
166 outliers_mask = pd.Series(False, index=df_muestra.index)
167 resumen_por_variable = []
168
169 for var in variables_outlier:
170     Q1 = df_muestra[var].quantile(0.25)

```



```

163     Q3 = df_muestra[var].quantile(0.75)
164     IQR = Q3 - Q1
165     lower_bound = Q1 - 1.5 * IQR
166     upper_bound = Q3 + 1.5 * IQR
167
168     var_mask = (df_muestra[var] < lower_bound) | (df_muestra[var] >
169         upper_bound)
170     outliers_mask = outliers_mask | var_mask
171
172     resumen_por_variable.append({
173         "Variable": var,
174         "Outliers detectados": int(var_mask.sum()),
175         "Porcentaje": f"{100 * var_mask.sum() / len(df_muestra):.2f}%",
176         "Límite inferior": f"{lower_bound:.2f}",
177         "Límite superior": f"{upper_bound:.2f}",
178         "Q1": f"{Q1:.2f}",
179         "Q3": f"{Q3:.2f}",
180         "IQR": f"{IQR:.2f}"
181     })
182
183     num_outliers = int(outliers_mask.sum())
184     total_rows = len(df_muestra)
185     pct_outliers = 100 * num_outliers / total_rows
186
187     # Exportación: tabla resumen de la detección de outliers, con una
188     # fila
189     # por variable analizada y una fila de totales (unión de las tres).
190     tabla_outliers = pd.DataFrame(resumen_por_variable)
191     tabla_outliers = pd.concat([
192         tabla_outliers,
193         pd.DataFrame([
194             "Variable": "TOTAL (unión de las 3 variables)",
195             "Outliers detectados": num_outliers,
196             "Porcentaje": f"{pct_outliers:.2f}%",
197             "Límite inferior": "-",
198             "Límite superior": "-",
199             "Q1": "-",
200             "Q3": "-",
201             "IQR": "-"
202         ])
203     ], ignore_index=True)
204
205     exportar_imagen("Doc/anexos/tabla_outliers_muestra.png")
206     dfi.export(tabla_outliers.style.hide(axis='index'),
207         "Doc/anexos/tabla_outliers_muestra.png")
208
209     print("\n--- Resumen de outliers (sobre la muestra) ---")

```

```

208 print(tabla_outliers.to_string(index=False))
209
210 # Exclusión de outliers para obtener la muestra de trabajo definitiva
211 df_muestra_clean = df_muestra[~outliers_mask].copy()
212 print(f"\nFilas después de excluir outliers: {len(df_muestra_clean)}"
    )
213
214 # Exportación: comparación de dimensiones muestra inicial vs. sin
    outliers
215 resumen_muestra = pd.DataFrame({
216     "Dataset": ["Muestra inicial (seed 42)", "Muestra sin outliers"],
217     "Filas": [df_muestra.shape[0], df_muestra_clean.shape[0]],
218     "Columnas": [df_muestra.shape[1], df_muestra_clean.shape[1]]
219 })
220 exportar_imagen("Doc/anexos/tabla_dimensiones_muestra.png")
221 dfi.export(resumen_muestra.style.hide(axis='index'),
222     "Doc/anexos/tabla_dimensiones_muestra.png")
223
224 # Exportación: primeras filas de la muestra limpia, redondeada a 2
225 # decimales. Se oculta el índice para mantener el mismo estilo visual
226 # que las demás tablas exportadas.
227 muestra_head = df_muestra_clean.head(5).round(2)
228 exportar_imagen("Doc/anexos/tabla_muestra_head.png")
229 dfi.export(muestra_head.style.hide(axis='index'),
230     "Doc/anexos/tabla_muestra_head.png")
231
232
233 # -----
234 # Análisis exploratorio: estadística descriptiva
235 # -----
236 # Se comparan df_muestra (1500 filas, con outliers) y
    df_muestra_clean
237 # (sin outliers en Valor FOB, Peso Neto y Cant. Unidades) para
238 # evidenciar el efecto del tratamiento de outliers sobre la forma de
239 # la distribución. Ambas provienen de la misma muestra base, por lo
240 # que el único factor que cambia entre ellas es el tratamiento de
241 # valores atípicos, no el tamaño muestral.
242
243 columnas_numericas = df_muestra.select_dtypes(include='number').
    columns.tolist()
244 print(f"Variables numéricas: {columnas_numericas}")
245
246 # Estadística descriptiva de las variables numéricas: se calcula con
247 # describe() y se agrega la asimetría (skew), que describe() no
    incluye.
248 estadisticos_con_outliers = df_muestra[columnas_numericas].describe()
    .T

```

```

249 estadisticos_con_outliers["Asimetría"] = df_muestra[
    columnas_numericas].apply(skew)
250 estadisticos_con_outliers = estadisticos_con_outliers.round(2)
251 print("\nEstadística descriptiva - muestra con outliers:\n",
    estadisticos_con_outliers)
252
253 exportar_imagen("Doc/anexos/tabla_estadisticos_con_outliers.png")
254 dfi.export(estadisticos_con_outliers, "Doc/anexos/
    tabla_estadisticos_con_outliers.png")
255
256 estadisticos_sin_outliers = df_muestra_clean[columnas_numericas].
    describe().T
257 estadisticos_sin_outliers["Asimetría"] = df_muestra_clean[
    columnas_numericas].apply(skew)
258 estadisticos_sin_outliers = estadisticos_sin_outliers.round(2)
259 print("\nEstadística descriptiva - muestra sin outliers:\n",
    estadisticos_sin_outliers)
260
261 exportar_imagen("Doc/anexos/tabla_estadisticos_sin_outliers.png")
262 dfi.export(estadisticos_sin_outliers, "Doc/anexos/
    tabla_estadisticos_sin_outliers.png")
263
264
265 # -----
266 # Análisis exploratorio: visualizaciones
267 # -----
268
269 # Histograma de Valor FOB, con y sin outliers.
270 plt.figure(figsize=(8, 5))
271 sns.histplot(df_muestra["Valor FOB (USD)"].dropna(), kde=True, color=
    "#4C72B0")
272 plt.title("Valor FOB (USD) - Muestra con outliers", fontsize=13)
273 plt.xlabel("Valor FOB (USD)")
274 plt.ylabel("Frecuencia")
275 plt.tight_layout()
276 exportar_imagen("Doc/anexos/histograma_valor_fob_con_outliers.png")
277 plt.savefig("Doc/anexos/histograma_valor_fob_con_outliers.png", dpi
    =300)
278 plt.close()
279
280 plt.figure(figsize=(8, 5))
281 sns.histplot(df_muestra_clean["Valor FOB (USD)"].dropna(), kde=True,
    color="#4C72B0")
282 plt.title("Valor FOB (USD) - Muestra sin outliers", fontsize=13)
283 plt.xlabel("Valor FOB (USD)")
284 plt.ylabel("Frecuencia")
285 plt.tight_layout()
286 exportar_imagen("Doc/anexos/histograma_valor_fob_sin_outliers.png")

```

```

287 plt.savefig("Doc/anexos/histograma_valor_fob_sin_outliers.png", dpi
    =300)
288 plt.close()
289
290 # Histograma de Peso Neto, con y sin outliers.
291 plt.figure(figsize=(8, 5))
292 sns.histplot(df_muestra["Peso Neto (Kg)"].dropna(), kde=True, color="#
    4C72B0")
293 plt.title("Peso Neto (Kg) - Muestra con outliers", fontsize=13)
294 plt.xlabel("Peso Neto (Kg)")
295 plt.ylabel("Frecuencia")
296 plt.tight_layout()
297 exportar_imagen("Doc/anexos/histograma_peso_netto_con_outliers.png")
298 plt.savefig("Doc/anexos/histograma_peso_netto_con_outliers.png", dpi
    =300)
299 plt.close()
300
301 plt.figure(figsize=(8, 5))
302 sns.histplot(df_muestra_clean["Peso Neto (Kg)"].dropna(), kde=True,
    color="#4C72B0")
303 plt.title("Peso Neto (Kg) - Muestra sin outliers", fontsize=13)
304 plt.xlabel("Peso Neto (Kg)")
305 plt.ylabel("Frecuencia")
306 plt.tight_layout()
307 exportar_imagen("Doc/anexos/histograma_peso_netto_sin_outliers.png")
308 plt.savefig("Doc/anexos/histograma_peso_netto_sin_outliers.png", dpi
    =300)
309 plt.close()
310
311
312 # -----
313 # Análisis exploratorio: verificación de normalidad
314 # -----
315 # Shapiro-Wilk + gráfico Q-Q para Valor FOB (USD), sobre la muestra
    ya
316 # depurada de outliers (df_muestra_clean), que es la que se usa en el
317 # resto del proyecto.
318
319 variable = df_muestra_clean['Valor FOB (USD)'].dropna()
320 print(f"\nRegistros válidos para la prueba: {len(variable)}")
321
322 estadistico_w, p_valor = shapiro(variable)
323
324 # Se reporta el valor p redondeado en formato decimal, no en notación
325 # científica. Cuando el valor es extremadamente pequeño (menor a
    0.001),
326 # se reporta como "< 0.001" en vez de un número con muchos ceros,

```

```

327 # siguiendo la convención estándar de reporte de pruebas de hipótesis
328
328 if p_valor < 0.001:
329     p_valor_str = "< 0.001"
330 else:
331     p_valor_str = f"{p_valor:.3f}"
332
333 print(f"\nEstadístico W: {estadistico_w:.4f}")
334 print(f"Valor p: {p_valor_str}")
335
336 alfa = 0.05
337 print(f"\nNivel de significancia (alfa): {alfa}")
338 if p_valor > alfa:
339     conclusion = "NO se rechaza H0. Los datos podrían provenir de una
340                 distribución normal (no hay evidencia suficiente en contra)."
341 else:
342     conclusion = "SE RECHAZA H0. Existe evidencia estadística
343                 significativa de que los datos NO siguen una distribución
344                 normal."
345 print(f"Conclusión: {conclusion}")
346
347 # Gráfico Q-Q de la muestra limpia, como evidencia visual que
348 # complementa el resultado numérico de Shapiro-Wilk.
349 plt.figure(figsize=(8, 6))
350 probplot(variable, dist="norm", plot=plt)
351 plt.title('Q-Q plot - Muestra sin outliers', fontsize=14)
352 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
353 plt.ylabel('Cuantiles muestrales', fontsize=12)
354 plt.grid(alpha=0.4)
355 plt.tight_layout()
356 exportar_imagen('Doc/anexos/qqplot_muestra_sin_outliers.png')
357 plt.savefig('Doc/anexos/qqplot_muestra_sin_outliers.png', dpi=300)
358 plt.close()

```