

[Título tentativo del proyecto]

Angie Montero

Michael Baquero

Analítica Descriptiva II

Unicafam

Agosto 2026

1. Introducción

2. Descripción del dataset

Los datos utilizados en este estudio provienen de la base de **Estadísticas de Comercio Exterior – Exportaciones**, publicada por la Dirección de Impuestos y Aduanas Nacionales (DIAN), validada y certificada por el Departamento Administrativo Nacional de Estadística (DANE). Corresponde al mes de junio de 2026 y fue descargada el 12 de agosto de 2026 desde la página oficial de estadísticas de comercio exterior de la DIAN.

El archivo original contiene un total de 103.179 registros y 72 variables. Dentro de este conjunto de datos, se identificaron 44 columnas de tipo numérico y 28 columnas de tipo categórico o texto, tal como se resume en la Tabla 1.

Dataset	Filas	Columnas	Columnas numéricas	Columnas categóricas/texto
Original	103179	72	44	28

Figura 1: Resumen del dataset original de exportaciones (junio 2026).

Exploración de variables categóricas

Para determinar qué variables categóricas eran adecuadas para las pruebas de hipótesis del proyecto, se realizó una exploración inicial sobre las variables candidatas: `MODO_TRANSPORTE`, `MODALIDAD_EXPORTACION`, `PAIS_DESTINO_FINAL`, `REGION_DE_ORIGEN` y `TIPO_DE_EMBARQUE`. El objetivo fue evaluar el número de categorías únicas presentes en cada una, ya que un número excesivo de categorías dificulta el análisis estadístico (Tabla 2).

Variable	Categorías únicas
<code>MODO_TRANSPORTE</code>	4
<code>MODALIDAD_EXPORTACION</code>	10
<code>PAIS_DESTINO_FINAL</code>	173
<code>REGION_DE_ORIGEN</code>	31
<code>TIPO_DE_EMBARQUE</code>	3

Figura 2: Número de categorías únicas por variable categórica candidata.

Con base en este análisis, se identificó que la variable `PAIS_DESTINO_FINAL` presenta un total de 173 categorías únicas. Esta alta cardinalidad la hace estadísticamente inviable para pruebas de hipótesis del tipo chi-cuadrado, ya que generaría una matriz de contingencia demasiado dispersa y sin poder explicativo. Por lo tanto, se decidió excluirla del análisis.

Selección de variables finales

Tras la exclusión de `PAIS_DESTINO_FINAL`, se seleccionaron 11 variables relevantes que orientan el desarrollo de la pregunta de investigación y el modelo de regresión final. Esta

selección incluye tanto variables cuantitativas (como valores monetarios y pesos) como variables categóricas de baja cardinalidad. La descripción técnica de cada variable seleccionada se presenta en la Tabla 3.

Variable	Tipo	Descripción
Valor FOB (USD)	float64	Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).
Peso Neto (Kg)	float64	Peso neto de la mercancía en kilogramos (sin incluir embalaje).
Peso Bruto (Kg)	float64	Peso bruto de la mercancía en kilogramos (incluyendo embalaje).
Vlr. Serie Nal (USD)	float64	Valor total de la serie agregada nacional en dólares.
Fletes (USD)	float64	Valor de los fletes internacionales en dólares.
Seguros (USD)	float64	Valor de los seguros internacionales en dólares.
Cant. Unidades	float64	Cantidad de unidades físicas de la mercancía.
Modo Transporte	object	Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).
Modalidad	object	Modalidad de exportación (definitiva, temporal, etc.).
Región Origen	object	Región de origen de la mercancía en Colombia.
Tipo Embarque	object	Tipo de embarque (único, consolidado, etc.).

Figura 3: Variables seleccionadas del dataset de exportaciones.

Muestreo y dimensiones finales

Dado el volumen del dataset filtrado y con el fin de optimizar los recursos computacionales, se optó por trabajar con una muestra aleatoria simple de 1.500 registros. Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados. Esta reducción evita sobrecargar el modelo de regresión lineal y reduce significativamente los tiempos de ejecución. La comparación de las dimensiones del dataset filtrado frente a la muestra de trabajo se observa en la Tabla 4.

Dataset	Filas	Columnas
Original (filtrado)	103179	11
Muestra de trabajo	1500	11

Figura 4: Comparación de dimensiones: dataset filtrado vs. muestra de trabajo (n=1500).

A modo de ejemplo tangible, la Tabla 5 presenta las primeras cinco filas de la muestra de trabajo. Se puede observar cómo se estructuran los datos de las variables cuantitativas y categóricas seleccionadas para el estudio.

	Valor FOB (USD)	Peso Neto (Kg)	Peso Bruto (Kg)	Vir. Serie Nal (USD)	Fletes (USD)	Seguros (USD)	Cant. Unidades	Modo Transporte	Modalidad	Región Origen	Tipo Embarque
0	1932.88	722.54	743.93	0.00	0.00	0.0	722.54	Marítimo	Exportación definitiva de mercancías de fabric...	ANTIOQUIA	Unico
1	2797.25	558.00	573.93	2412.38	215.88	0.0	9.00	Terrestre (carretero)	Las demás exportaciones definitivas no incluid...	CALDAS	Unico
2	530.91	23.26	28.75	0.00	0.00	0.0	23.26	Terrestre (carretero)	Exportación definitiva de mercancías de fabric...	ANTIOQUIA	Unico
3	280.00	63.55	64.65	0.00	0.00	0.0	63.55	Terrestre (carretero)	Exportación definitiva de mercancías de fabric...	NORTE DE SANTANDER	Unico
4	715.59	224.71	229.30	0.00	0.00	0.0	224.71	Aéreo	Exportación definitiva de mercancías de fabric...	CUNDINAMARCA	Unico

Figura 5: Primeras 5 filas de la muestra de trabajo (n=1500).

3. Análisis exploratorio

3.1. Estadística descriptiva

3.2. Visualizaciones

3.3. Verificación de normalidad

Referencias

A. Apéndice: Código fuente

```
1 # =====
2 # Proyecto Integrador - Analítica Descriptiva II
3 # Avance 1: EDA - Exportaciones Colombia (DIAN, Junio 2026)
4 # Fuente: https://www.dian.gov.co/dian/cifras/Paginas/
   EstadisticasComEx.aspx
5 # Fecha de descarga del archivo: 12/08/2026
6 # =====
7
8 # Importe de librerías
9 import pandas as pd
10 import dataframe_image as dfi
11
12 # Lectura del documento
13 df = pd.read_excel("Data/06_Exportaciones_2026_Junio.xlsx")
14
15 # Visualización inicial del dataframe:
16 # - Primeras 5 filas del dataframe
17 # - Dimensiones del dataframe
18 # - Tipos de datos y valores nulos
19 print('Visualización de primeras filas:\n', df.head(5))
20 print('\nVisualización de las dimensiones: ', df.shape)
21 print(df.info())
22
23 # -----
24 # 1. Exportación: resumen del dataset ORIGINAL (dimensiones y tipos
   de dato)
25 # Nota: Se usa .style.hide(axis='index') porque dataframe_image no
   soporta index=False.
26 # -----
27 resumen_original = pd.DataFrame({
28     "Dataset": ["Original"],
29     "Filas": [df.shape[0]],
30     "Columnas": [df.shape[1]],
31     "Columnas numéricas": [df.select_dtypes(include="number").shape
        [1]],
32     "Columnas categóricas/texto": [df.select_dtypes(include="object")
        .shape[1]]
33 })
34 dfi.export(resumen_original.style.hide(axis='index'), "Doc/anexos/
   tabla_resumen_original.png")
35
36 # Exploración preliminar de variables categóricas candidatas, ANTES
   de
37 # decidir cuáles incluir en el análisis. Se revisan sobre el dataset
38 # ORIGINAL (df), incluyendo PAIS_DESTINO_FINAL, para que la selección
```

```

39 # posterior de columnas quede sustentada en esta evidencia.
40 categoricas_candidatas = [
41     "MODO_TRANSPORTE",
42     "MODALIDAD_EXPORTACION",
43     "PAIS_DESTINO_FINAL",
44     "REGION_DE_ORIGEN",
45     "TIPO_DE_EMBARQUE"
46 ]
47 for col in categoricas_candidatas:
48     print(col, "->", df[col].nunique(), "categorías únicas")
49
50 # -----
51 # 2. Exportación: número de categorías únicas por variable categórica
   candidata.
52 # Esta tabla es la evidencia que sustenta la exclusión de
   PAIS_DESTINO_FINAL
53 # (173 categorías, inviable para pruebas de hipótesis tipo chi-
   cuadrado)
54 # frente a las demás variables categóricas, que sí son manejables.
55 # -----
56 resumen_categoricas = pd.DataFrame({
57     "Variable": categoricas_candidatas,
58     "Categorías únicas": [df[col].nunique() for col in
   categoricas_candidatas]
59 })
60 dfi.export(resumen_categoricas.style.hide(axis='index'), "Doc/anexos/
   tabla_categoricas.png")
61
62 # Con base en la exploración anterior, se realiza el filtro de
   columnas
63 # categóricas y numéricas apropiadas para orientar el desarrollo de
   la
64 # pregunta de investigación y el modelo de regresión final. Se
   excluye
65 # PAIS_DESTINO_FINAL por el resultado mostrado en la tabla anterior
66 # (173 categorías únicas).
67 columnas_relevantes = [
68     "VALOR_FOB_USD",
69     "PESO_NETO_KGS",
70     "PESO_BRUTO_KGS",
71     "VLR_SERIE_AGREGADO_NAL_USD",
72     "VALOR_SERIE_FLETES_USD",
73     "VALOR_SERIE_SEGUROS_USD",
74     "CANTIDAD_UNIDADES_FISICAS",
75     "MODO_TRANSPORTE",
76     "MODALIDAD_EXPORTACION",
77     "REGION_DE_ORIGEN",
78     "TIPO_DE_EMBARQUE"

```

```

79 ]
80 df_filtrado = df[columnas_relevantes]
81
82 # -----
83 # RENOMBRADO DE COLUMNAS
84 # Se renombran las variables a nombres cortos y legibles antes de
    exportar
85 # las imágenes, para evitar que los nombres técnicos desborden
86 # el ancho de la página del documento LaTeX.
87 # -----
88 renombres = {
89     "VALOR_FOB_USD": "Valor FOB (USD)",
90     "PESO_NETO_KGS": "Peso Neto (Kg)",
91     "PESO_BRUTO_KGS": "Peso Bruto (Kg)",
92     "VLR_SERIE_AGREGADO_NAL_USD": "Vlr. Serie Nal (USD)",
93     "VALOR_SERIE_FLETES_USD": "Fletes (USD)",
94     "VALOR_SERIE_SEGUROS_USD": "Seguros (USD)",
95     "CANTIDAD_UNIDADES_FISICAS": "Cant. Unidades",
96     "MODO_TRANSPORTE": "Modo Transporte",
97     "MODALIDAD_EXPORTACION": "Modalidad",
98     "REGION_DE_ORIGEN": "Región Origen",
99     "TIPO_DE_EMBARQUE": "Tipo Embarque"
100 }
101 df_filtrado = df_filtrado.rename(columns=renombres)
102
103 # -----
104 # DESCRIPCIONES TÉCNICAS DE LAS VARIABLES
105 # Se crea un diccionario con la descripción semántica de cada
    variable
106 # para llenar automáticamente la columna "Descripción" en la tabla
107 # de variables seleccionadas.
108 # -----
109 descripciones = {
110     "VALOR_FOB_USD": "Valor de la mercancía en dólares (FOB: Free On
        Board, sin fletes ni seguros).",
111     "PESO_NETO_KGS": "Peso neto de la mercancía en kilogramos (sin
        incluir embalaje).",
112     "PESO_BRUTO_KGS": "Peso bruto de la mercancía en kilogramos (
        incluyendo embalaje).",
113     "VLR_SERIE_AGREGADO_NAL_USD": "Valor total de la serie agregada
        nacional en dólares.",
114     "VALOR_SERIE_FLETES_USD": "Valor de los fletes internacionales en
        dólares.",
115     "VALOR_SERIE_SEGUROS_USD": "Valor de los seguros internacionales
        en dólares.",
116     "CANTIDAD_UNIDADES_FISICAS": "Cantidad de unidades físicas de la
        mercancía.",

```

```

117     "MODO_TRANSPORTE": "Modo de transporte utilizado (marítimo, aéreo
    , terrestre, etc.).",
118     "MODALIDAD_EXPORTACION": "Modalidad de exportación (definitiva,
    temporal, etc.).",
119     "REGION_DE_ORIGEN": "Región de origen de la mercancía en Colombia
    .",
120     "TIPO_DE_EMBARQUE": "Tipo de embarque (único, consolidado, etc.).
    "
121 }
122
123 # -----
124 # 3. Exportación: tabla de variables seleccionadas (nombre, tipo y
    descripción).
125 # La descripción se llena automáticamente gracias al diccionario
    creado arriba.
126 # -----
127 tabla_variables = pd.DataFrame({
128     "Variable": [renombres[col] for col in columnas_relevantes],
129     "Tipo": [str(df_filtrado[col].dtype) for col in df_filtrado.
        columns],
130     "Descripción": [descripciones[col] for col in columnas_relevantes
        ]
131 })
132 dfi.export(tabla_variables.style.hide(axis='index'), "Doc/anexos/
    tabla_variables_seleccionadas.png")
133
134 # Se validan valores nulos para columnas seleccionadas
135 print('\nVisualización de valores nulos:\n', df_filtrado.isnull().sum
    ())
136
137 # -----
138 # 4. MUESTRA DE TRABAJO
139 # Con fines de optimizar el código y evitar saturación en el modelo
    de
140 # regresión lineal:
141 # - Se delimita una muestra de 1500 registros para el desarrollo del
    proyecto
142 # - random_state=42 fija la semilla para garantizar reproducibilidad
143 # - .reset_index(drop=True) reinicia los índices para que la tabla
    final
144 # muestre una secuencia limpia (0, 1, 2, 3, 4) en lugar de índices
    aleatorios.
145 # -----
146 df_muestra = df_filtrado.sample(n=1500, random_state=42).reset_index(
    drop=True)
147 print('\nVisualización de las nuevas dimensiones: ', df_muestra.shape
    )
148 print('\nVisualización de primeras filas:\n', df_muestra.head(5))

```

```

149 # -----
150 # 5. Exportación: comparación de dimensiones dataset original vs.
151 # muestra.
152 # Sustenta la justificación del volumen y técnica de muestreo en el
153 # texto.
154 # -----
155 resumen_muestra = pd.DataFrame({
156     "Dataset": ["Original (filtrado)", "Muestra de trabajo"],
157     "Filas": [df_filtrado.shape[0], df_muestra.shape[0]],
158     "Columnas": [df_filtrado.shape[1], df_muestra.shape[1]]
159 })
160 dfi.export(resumen_muestra.style.hide(axis='index'), "Doc/anexos/
161     tabla_dimensiones_muestra.png")
162 # -----
163 # 6. Exportación: primeras filas de la muestra final.
164 # Se redondea a 2 decimales para que la imagen se vea más limpia.
165 # (Se deja el índice visible 0, 1, 2, 3, 4 tal como se acordó para la
166 # muestra).
167 # -----
168 muestra_head = df_muestra.head(5).round(2)
169 dfi.export(muestra_head, "Doc/anexos/tabla_muestra_head.png")
170 # =====
171 # TODOs pendientes para el siguiente avance
172 # =====
173 """
174 TODO (Angie): Estadísticas descriptivas y visualizaciones
175
176 Continuar el desarrollo del EDA sobre df_muestra:
177
178 1. Estadística descriptiva para las variables cuantitativas
179    (media, mediana, desviación estándar, mínimo, máximo, asimetría):
180    df_muestra.describe() |
181    df_muestra.skew(numeric_only=True)
182
183 2. Mínimo dos visualizaciones con su interpretación escrita
184    (histograma, boxplot, gráfico de barras, etc.) sobre las
185    variables de df_muestra.
186 """
187
188 # TODO (Michael): Verificación de normalidad (Shapiro-Wilk + gráfico
189 # Q-Q)
190 # para al menos una variable cuantitativa de df_muestra.
191 # from scipy import stats
192 # stats.shapiro(df_muestra["Valor FOB (USD)"])

```
