

Análisis Exploratorio de Exportaciones Colombianas (Junio 2026)

Angie Montero

Michael Baquero

Analítica Descriptiva II

Unicafam

Agosto 2026

1. Introducción

2. Descripción del dataset

Los datos utilizados en este estudio provienen de la base de **Estadísticas de Comercio Exterior – Exportaciones**, publicada por la Dirección de Impuestos y Aduanas Nacionales (DIAN), validada y certificada por el Departamento Administrativo Nacional de Estadística (DANE). Corresponde al mes de junio de 2026 y fue descargada el 12 de agosto de 2026 desde la página oficial de estadísticas de comercio exterior de la DIAN.

El archivo original contiene un total de 103.179 registros y 72 variables. Dentro de este conjunto de datos, se identificaron 44 columnas de tipo numérico y 28 columnas de tipo categórico o texto, tal como se resume en la Tabla 1.

Dataset	Filas	Columnas	Columnas numéricas	Columnas categóricas/texto
Original	103179	72	44	28

Figura 1: Resumen del dataset original de exportaciones (junio 2026).

Exploración de variables categóricas

Para determinar qué variables categóricas eran adecuadas para las pruebas de hipótesis del proyecto, se realizó una exploración inicial sobre las variables candidatas: `MODO_TRANSPORTE`, `MODALIDAD_EXPORTACION`, `PAIS_DESTINO_FINAL`, `REGION_DE_ORIGEN` y `TIPO_DE_EMBARQUE`. El objetivo fue evaluar el número de categorías únicas presentes en cada una, ya que un número excesivo de categorías dificulta el análisis estadístico (Tabla 2).

Variable	Categorías únicas
<code>MODO_TRANSPORTE</code>	4
<code>MODALIDAD_EXPORTACION</code>	10
<code>PAIS_DESTINO_FINAL</code>	173
<code>REGION_DE_ORIGEN</code>	31
<code>TIPO_DE_EMBARQUE</code>	3

Figura 2: Número de categorías únicas por variable categórica candidata.

Con base en este análisis, se identificó que la variable `PAIS_DESTINO_FINAL` presenta un total de 173 categorías únicas. Esta alta cardinalidad la hace estadísticamente inviable para pruebas de hipótesis del tipo chi-cuadrado, ya que generaría una matriz de contingencia demasiado dispersa y sin poder explicativo. Por lo tanto, se decidió excluirla del análisis.

Selección de variables finales

Tras la exclusión de `PAIS_DESTINO_FINAL`, se seleccionaron 11 variables relevantes que orientan el desarrollo de la pregunta de investigación y el modelo de regresión final. Esta

selección incluye tanto variables cuantitativas (como valores monetarios y pesos) como variables categóricas de baja cardinalidad. La descripción técnica de cada variable seleccionada se presenta en la Tabla 3.

Variable	Tipo	Descripción
Valor FOB (USD)	float64	Valor de la mercancía en dólares (FOB: Free On Board, sin fletes ni seguros).
Peso Neto (Kg)	float64	Peso neto de la mercancía en kilogramos (sin incluir embalaje).
Peso Bruto (Kg)	float64	Peso bruto de la mercancía en kilogramos (incluyendo embalaje).
Vlr. Serie Nal (USD)	float64	Valor total de la serie agregada nacional en dólares.
Fletes (USD)	float64	Valor de los fletes internacionales en dólares.
Seguros (USD)	float64	Valor de los seguros internacionales en dólares.
Cant. Unidades	float64	Cantidad de unidades físicas de la mercancía.
Modo Transporte	object	Modo de transporte utilizado (marítimo, aéreo, terrestre, etc.).
Modalidad	object	Modalidad de exportación (definitiva, temporal, etc.).
Región Origen	object	Región de origen de la mercancía en Colombia.
Tipo Embarque	object	Tipo de embarque (único, consolidado, etc.).

Figura 3: Variables seleccionadas del dataset de exportaciones.

Muestreo y dimensiones finales

Dado el volumen del dataset filtrado y con el fin de optimizar los recursos computacionales, se optó por trabajar con una muestra aleatoria simple de 1.500 registros. Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados. Esta reducción evita sobrecargar el modelo de regresión lineal y reduce significativamente los tiempos de ejecución. La comparación de las dimensiones del dataset filtrado frente a la muestra de trabajo se observa en la Tabla 4.

Dataset	Filas	Columnas
Original (filtrado)	103179	11
Muestra de trabajo	1500	11

Figura 4: Comparación de dimensiones: dataset filtrado vs. muestra de trabajo (n=1500).

A modo de ejemplo tangible, la Tabla 5 presenta las primeras cinco filas de la muestra de trabajo. Se puede observar cómo se estructuran los datos de las variables cuantitativas y categóricas seleccionadas para el estudio.

	Valor FOB (USD)	Peso Neto (Kg)	Peso Bruto (Kg)	Vir. Serie Nal (USD)	Fletes (USD)	Seguros (USD)	Cant. Unidades	Modo Transporte	Modalidad	Región Origen	Tipo Embarque
0	1932.88	722.54	743.93	0.00	0.00	0.0	722.54	Marítimo	Exportación definitiva de mercancías de fabric...	ANTIOQUIA	Unico
1	2797.25	558.00	573.93	2412.38	215.88	0.0	9.00	Terrestre (carretero)	Las demás exportaciones definitivas no incluid...	CALDAS	Unico
2	530.91	23.26	28.75	0.00	0.00	0.0	23.26	Terrestre (carretero)	Exportación definitiva de mercancías de fabric...	ANTIOQUIA	Unico
3	280.00	63.55	64.65	0.00	0.00	0.0	63.55	Terrestre (carretero)	Exportación definitiva de mercancías de fabric...	NORTE DE SANTANDER	Unico
4	715.59	224.71	229.30	0.00	0.00	0.0	224.71	Aéreo	Exportación definitiva de mercancías de fabric...	CUNDINAMARCA	Unico

Figura 5: Primeras 5 filas de la muestra de trabajo (n=1500).

3. Análisis exploratorio

3.1. Estadística descriptiva

3.2. Visualizaciones

3.3. Verificación de normalidad

Para evaluar el supuesto de normalidad de la variable cuantitativa *Valor FOB (USD)*, se aplicó la prueba de Shapiro-Wilk sobre la muestra de 1.500 registros. Esta prueba contrasta la hipótesis nula de que los datos provienen de una distribución normal.

Los resultados obtenidos fueron los siguientes:

- Estadístico de prueba (W): **0.024734**
- Valor p : $8,77 \times 10^{-66}$

Dado que el valor p es muy inferior al nivel de significancia $\alpha = 0,05$, se **rechaza la hipótesis nula**. Por lo tanto, existe evidencia estadística sumamente significativa de que la variable *Valor FOB (USD)* **no sigue una distribución normal**.

Este hallazgo se complementa con el gráfico Q-Q presentado en la Figura 6, donde se observa que los puntos se desvían claramente de la línea de referencia en los cuantiles superiores, confirmando la presencia de colas pesadas y valores atípicos.

En consecuencia, para el modelo de regresión lineal que se desarrollará en etapas posteriores, se recomienda aplicar una transformación logarítmica a esta variable con el fin de aproximar su comportamiento a una distribución normal y cumplir con los supuestos del modelo.




Figura 6: Gráfico Q-Q para la variable Valor FOB (USD).

Referencias

Referencias

- [1] Dirección de Impuestos y Aduanas Nacionales - DIAN. (2026). *Estadísticas de comercio exterior - Exportaciones (junio 2026)*. Recuperado de <https://www.dian.gov.co/dian/cifras/Paginas/Bases-Estadisticas-de-Comercio-Exterior-Importaciones-y-Exportaciones.aspx>
- [2] Departamento Administrativo Nacional de Estadística - DANE. (2026). *Comercio exterior: Metodología y validación de estadísticas de exportaciones*. Recuperado de <https://www.dane.gov.co>
- [3] Montgomery, D. C., & Runger, G. C. (2018). *Applied statistics and probability for engineers* (7th ed.). Wiley.
- [4] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3/4), 591–611. <https://doi.org/10.2307/2333709>

A. Apéndice: Código fuente

```
1 # =====
2 # Proyecto Integrador - Analítica Descriptiva II
3 # Avance 1: EDA - Exportaciones Colombia (DIAN, Junio 2026)
4 # Fuente: https://www.dian.gov.co/dian/cifras/Paginas/
   EstadisticasComEx.aspx
5 # Fecha de descarga del archivo: 12/08/2026
6 # Equipo: Angie Montero, Michael Baquero
7 # =====
8
9 # Importe de librerías
10 import pandas as pd
11 import dataframe_image as dfi
12 import matplotlib.pyplot as plt
13 import seaborn as sns
14 from scipy.stats import shapiro, probplot, skew
15
16 # Lectura del documento
17 df = pd.read_excel("Data/06_Exportaciones_2026_Junio.xlsx")
18
19 # Visualización inicial del dataframe:
20 # - Primeras 5 filas del dataframe
21 # - Dimensiones del dataframe
22 # - Tipos de datos y valores nulos
23 print('Visualización de primeras filas:\n', df.head(5))
24 print('\nVisualización de las dimensiones: ', df.shape)
25 print(df.info())
26
27 # Exportación: resumen del dataset ORIGINAL (dimensiones y tipos de
   dato)
28 # para incluir en la sección de Descripción del dataset del artículo.
29 # Se usa .style.hide(axis='index') porque dataframe_image no soporta
30 # el parámetro index=False que sí acepta to_latex().
31 resumen_original = pd.DataFrame({
32     "Dataset": ["Original"],
33     "Filas": [df.shape[0]],
34     "Columnas": [df.shape[1]],
35     "Columnas numéricas": [df.select_dtypes(include="number").shape
   [1]],
36     "Columnas categóricas/texto": [df.select_dtypes(include="object")
   .shape[1]]
37 })
38 dfi.export(resumen_original.style.hide(axis='index'),
39            "Doc/anexos/tabla_resumen_original.png")
40
```

```

41 # Exploración preliminar de variables categóricas candidatas, ANTES
    de
42 # decidir cuáles incluir en el análisis. Se revisan sobre el dataset
43 # ORIGINAL (df), incluyendo PAIS_DESTINO_FINAL, para que la selección
44 # posterior de columnas quede sustentada en esta evidencia.
45 categoricas_candidatas = [
46     "MODO_TRANSPORTE",
47     "MODALIDAD_EXPORTACION",
48     "PAIS_DESTINO_FINAL",
49     "REGION_DE_ORIGEN",
50     "TIPO_DE_EMBARQUE"
51 ]
52 for col in categoricas_candidatas:
53     print(col, "->", df[col].nunique(), "categorías únicas")
54
55 # Exportación: número de categorías únicas por variable categórica
    candidata.
56 # Esta tabla es la evidencia que sustenta la exclusión de
    PAIS_DESTINO_FINAL
57 # (173 categorías, inviable para pruebas de hipótesis tipo chi-
    cuadrado)
58 # frente a las demás variables categóricas, que sí son manejables.
59 resumen_categoricas = pd.DataFrame({
60     "Variable": categoricas_candidatas,
61     "Categorías únicas": [df[col].nunique() for col in
        categoricas_candidatas]
62 })
63 dfi.export(resumen_categoricas.style.hide(axis='index'),
64            "Doc/anexos/tabla_categoricas.png")
65
66 # Con base en la exploración anterior, se realiza el filtro de
    columnas
67 # categóricas y numéricas apropiadas para orientar el desarrollo de
    la
68 # pregunta de investigación y el modelo de regresión final. Se
    excluye
69 # PAIS_DESTINO_FINAL por el resultado mostrado en la tabla anterior
70 # (173 categorías únicas).
71 columnas_relevantes = [
72     "VALOR_FOB_USD",
73     "PESO_NETO_KGS",
74     "PESO_BRUTO_KGS",
75     "VLR_SERIE_AGREGADO_NAL_USD",
76     "VALOR_SERIE_FLETES_USD",
77     "VALOR_SERIE_SEGUROS_USD",
78     "CANTIDAD_UNIDADES_FISICAS",
79     "MODO_TRANSPORTE",
80     "MODALIDAD_EXPORTACION",

```



```

81     "REGION_DE_ORIGEN",
82     "TIPO_DE_EMBARQUE"
83 ]
84 df_filtrado = df[columnas_relevantes]
85
86 # Se renombran las variables a nombres cortos y legibles antes de
87   exportar
88 # las imágenes, para evitar que los nombres técnicos desborden el
89   ancho
90 # de la página del documento LaTeX.
91 renombres = {
92     "VALOR_FOB_USD": "Valor FOB (USD)",
93     "PESO_NETO_KGS": "Peso Neto (Kg)",
94     "PESO_BRUTO_KGS": "Peso Bruto (Kg)",
95     "VLR_SERIE_AGREGADO_NAL_USD": "Vlr. Serie Nal (USD)",
96     "VALOR_SERIE_FLETES_USD": "Fletes (USD)",
97     "VALOR_SERIE_SEGUROS_USD": "Seguros (USD)",
98     "CANTIDAD_UNIDADES_FISICAS": "Cant. Unidades",
99     "MODO_TRANSPORTE": "Modo Transporte",
100    "MODALIDAD_EXPORTACION": "Modalidad",
101    "REGION_DE_ORIGEN": "Región Origen",
102    "TIPO_DE_EMBARQUE": "Tipo Embarque"
103 }
104 df_filtrado = df_filtrado.rename(columns=renombres)
105
106 # Diccionario con la descripción semántica de cada variable, usado
107   para
108 # llenar automáticamente la columna "Descripción" en la tabla de
109 # variables seleccionadas.
110 descripciones = {
111     "VALOR_FOB_USD": "Valor de la mercancía en dólares (FOB: Free On
112       Board, sin fletes ni seguros).",
113     "PESO_NETO_KGS": "Peso neto de la mercancía en kilogramos (sin
114       incluir embalaje).",
115     "PESO_BRUTO_KGS": "Peso bruto de la mercancía en kilogramos (
116       incluyendo embalaje).",
117     "VLR_SERIE_AGREGADO_NAL_USD": "Valor total de la serie agregada
118       nacional en dólares.",
119     "VALOR_SERIE_FLETES_USD": "Valor de los fletes internacionales en
120       dólares.",
121     "VALOR_SERIE_SEGUROS_USD": "Valor de los seguros internacionales
122       en dólares.",
123     "CANTIDAD_UNIDADES_FISICAS": "Cantidad de unidades físicas de la
124       mercancía.",
125     "MODO_TRANSPORTE": "Modo de transporte utilizado (marítimo, aéreo
126       , terrestre, etc.).",
127     "MODALIDAD_EXPORTACION": "Modalidad de exportación (definitiva,
128       temporal, etc.).",

```

```

117     "REGION_DE_ORIGEN": "Región de origen de la mercancía en Colombia
118     .",
119     "TIPO_DE_EMBARQUE": "Tipo de embarque (único, consolidado, etc.).
120     "
121 }
122 # Exportación: tabla de variables seleccionadas (nombre, tipo y
123     descripción).
124 tabla_variables = pd.DataFrame({
125     "Variable": [renombres[col] for col in columnas_relevantes],
126     "Tipo": [str(df_filtrado[col].dtype) for col in df_filtrado.
127         columns],
128     "Descripción": [descripciones[col] for col in columnas_relevantes
129         ]
130 })
131 dfi.export(tabla_variables.style.hide(axis='index'),
132     "Doc/anexos/tabla_variables_seleccionadas.png")
133 # Se validan valores nulos para columnas seleccionadas
134 print('\nVisualización de valores nulos:\n', df_filtrado.isnull().sum
135     ())
136 # Con fines de optimizar el código y evitar saturación en el modelo
137 # de
138 # regresión lineal:
139 # - Se delimita una muestra de 1500 registros para el desarrollo del
140 # proyecto
141 # - random_state=42 fija la semilla para garantizar reproducibilidad
142 # - reset_index(drop=True) reinicia los índices para que la tabla
143 # final
144 # muestre una secuencia limpia (0, 1, 2, 3, 4) en lugar de índices
145 # aleatorios
146 df_muestra = df_filtrado.sample(n=1500, random_state=42).reset_index(
147     drop=True)
148 print('\nVisualización de las nuevas dimensiones: ', df_muestra.shape
149     )
150 print('\nVisualización de primeras filas:\n', df_muestra.head(5))
151 # Exportación: comparación de dimensiones dataset original vs.
152     muestra.
153 # Sustenta la justificación del volumen y técnica de muestreo en el
154     texto.
155 resumen_muestra = pd.DataFrame({
156     "Dataset": ["Original (filtrado)", "Muestra de trabajo"],
157     "Filas": [df_filtrado.shape[0], df_muestra.shape[0]],
158     "Columnas": [df_filtrado.shape[1], df_muestra.shape[1]]
159 })
160 dfi.export(resumen_muestra.style.hide(axis='index'),

```

```

151         "Doc/anexos/tabla_dimensiones_muestra.png")
152
153 # Exportación: primeras filas de la muestra final, redondeada a 2
    decimales
154 # para que la imagen se vea más limpia.
155 muestra_head = df_muestra.head(5).round(2)
156 dfi.export(muestra_head, "Doc/anexos/tabla_muestra_head.png")
157
158
159 # Sección a cargo de Angie: estadística descriptiva y visualizaciones
160 # sobre las variables numéricas de df_muestra.
161
162 # Estadística descriptiva de las variables numéricas: se calcula con
163 # describe() y se agrega la asimetría (skew), que describe() no
    incluye.
164 columnas_numericas = df_muestra.select_dtypes(include='number').
    columns.tolist()
165 print(f"Variables numéricas: {columnas_numericas}")
166
167 estadisticos = df_muestra[columnas_numericas].describe()
168 sesgos = df_muestra[columnas_numericas].apply(lambda x: skew(x.dropna
    ()))
169 estadisticos.loc['Sesgo'] = sesgos
170
171 # Se renombran los índices para que la tabla exportada sea más
    legible
172 # que los nombres técnicos que usa pandas por defecto (count, mean,
    std...).
173 estadisticos.index = [
174     'Conteo', 'Media', 'Desv. Est.', 'Mínimo', 'Q1 (25%)',
175     'Mediana (50%)', 'Q3 (75%)', 'Máximo', 'Sesgo'
176 ]
177
178 # Exportación: tabla de estadística descriptiva, para la sección de
179 # Análisis exploratorio del artículo.
180 estadisticos_rounded = estadisticos.round(2)
181 dfi.export(estadisticos_rounded.style.hide(axis='index'),
182             "Doc/anexos/tabla_estadisticos.png")
183
184 # Visualización 1: boxplot de Valor FOB, para identificar outliers.
185 plt.figure(figsize=(8, 6))
186 sns.boxplot(y=df_muestra['Valor FOB (USD)'], color='steelblue')
187 plt.title('Boxplot - Valor FOB (USD)', fontsize=14)
188 plt.ylabel('Valor FOB (USD)', fontsize=12)
189 plt.tight_layout()
190 plt.savefig('Doc/anexos/boxplot_valor_fob.png', dpi=300)
191 plt.close()
192

```

```

193 # Visualización 2: histograma de Peso Neto, para observar la forma
194 # de la distribución (asimetría, colas).
195 plt.figure(figsize=(8, 6))
196 sns.histplot(df_muestra['Peso Neto (Kg)'], bins=30, kde=True, color='
    forestgreen')
197 plt.title('Distribución del Peso Neto (Kg)', fontsize=14)
198 plt.xlabel('Peso Neto (Kg)', fontsize=12)
199 plt.ylabel('Frecuencia', fontsize=12)
200 plt.tight_layout()
201 plt.savefig('Doc/anexos/histograma_peso_netto.png', dpi=300)
202 plt.close()
203
204
205 # Sección a cargo de Michael: verificación de normalidad
206 # (Shapiro-Wilk + gráfico Q-Q) para Valor FOB (USD).
207
208 # Se eliminan nulos por seguridad antes de correr la prueba, aunque
    ya
209 # se confirmó que df_filtrado no los tiene.
210 variable = df_muestra['Valor FOB (USD)'].dropna()
211 print(f"Registros válidos para la prueba: {len(variable)}")
212
213 estadistico_w, p_valor = shapiro(variable)
214 print(f"\nEstadístico W: {estadistico_w:.6f}")
215 print(f"Valor p: {p_valor:.6e}")
216
217 # Conclusión estadística con nivel de significancia alfa = 0.05.
218 alfa = 0.05
219 print(f"\nNivel de significancia (alfa): {alfa}")
220 if p_valor > alfa:
221     conclusion = "NO se rechaza H0. Los datos podrían provenir de una
        distribución normal (no hay evidencia suficiente en contra)."
222 else:
223     conclusion = "SE RECHAZA H0. Existe evidencia estadística
        significativa de que los datos NO siguen una distribución
        normal."
224 print(f"Conclusión: {conclusion}")
225
226 # Gráfico Q-Q para la misma variable, como evidencia visual que
227 # complementa el resultado numérico de Shapiro-Wilk.
228 plt.figure(figsize=(8, 6))
229 probplot(variable, dist="norm", plot=plt)
230 plt.title('Gráfico Q-Q - Valor FOB (USD)', fontsize=14)
231 plt.xlabel('Cuantiles teóricos (normal)', fontsize=12)
232 plt.ylabel('Cuantiles muestrales', fontsize=12)
233 plt.grid(alpha=0.4)
234 plt.tight_layout()
235 plt.savefig('Doc/anexos/qqplot_valor_fob.png', dpi=300)

```

```
236 plt.close()
```